STRIPE AI INFRASTRUCTURE • CERTIFICATION BLOC 2 (RNCP 41993)

Executive Summary — Architecture Data & IA Stripe

Stripe traite chaque jour plusieurs dizaines de millions de transactions financières pour des millions d'entreprises à travers plus de 135 pays et devises. À cette échelle planétaire, la plateforme doit garantir la convergence de **trois univers de données hétérogènes**, tout en propulsant en continu son moteur d'IA phare : **Stripe Radar** (détection de fraude en temps réel) :

1. **Monde Transactionnel (OLTP) :** Encaissement critique, abonnements, remboursements et virements. Ce flux exige une tolérance zéro à la panne (99.999% d'uptime), des garanties strictes **ACID**, une latence de validation inférieure à 15 ms et une protection absolue contre les doubles débits via l'idempotence.
2. **Monde Analytique (OLAP) :** Agrégation de volumes colossaux d'historique pour le calcul du chiffre d'affaires, le reporting comptable, le suivi du churn, l'analyse des contestations (chargebacks) et les dashboards marchands.
3. **Monde Non Structuré & Télémétrie (NoSQL) :** Capture à très haute cadence des traces de navigation (clickstream), des empreintes matérielles (device fingerprinting), des logs d'appels API et des webhooks marchands.
4. **Moteur d'IA Stripe Radar (< 100 ms) :** Scoring probabiliste en ligne de chaque transaction entrante en moins de 100 ms, combiné à un réentraînement périodique automatisé (batch) sur des téraoctets d'historique de paiements étiquetés.

2. Les Défis Majeurs & Contraintes Non Négociables

Axe	Défi Critique	Réponse Architecturale Adoptée
Disponibilité & Résilience	Zéro perte de transaction, continuité de service 24/7/365	Architecture Multi-AZ sur 3 Zones de Disponibilité (AWS `eu-west-3`), réplication synchrone Aurora PostgreSQL avec basculement automatique (< 30s), **RPO = 0**, **RTO < 60s**.
Latence d'Inférence IA	Scoring de fraude sous la barre stricte des 100 ms	Découplage strict via un microservice d'inférence containerisé (EKS), Feature Store Feast sur mémoire vive (Redis ElastiCache, latence < 5 ms), recherche vectorielle de motifs de fraude et inférence ONNX Runtime (~30 ms). Budget total : **~95 ms**.
Conformité & Souveraineté	PCI-DSS v4.0 Level 1 & RGPD européen	Cloisonnement réseau en 3 tiers étanches, Tokenization Vault isolant les données bancaires (PAN/CVV), chiffrement AES-256 (AWS KMS CMK) au repos et TLS 1.3 en transit, hébergement souverain en France (`eu-west-3`).
Maîtrise Économique (FinOps)	Facture cloud prévisible et optimisée pour le CFO	Séparation nette du compute et du stockage, instances réservées (Savings Plans) pour le socle 24/7, instances Spot éphémères pour l'entraînement GPU ML, cycle de vie S3 vers Glacier.
Impact Environnemental (GreenOps)	Réduction de l'empreinte carbone numérique	Choix de la région Paris (`eu-west-3`) au mix électrique bas-carbone, extinction automatique des clusters d'entraînement ML après exécution (anti-idle).

3. Synthèse des Choix d'Architecture Technologique



Justification Rapide des Briques Clés :

- **OLTP — Amazon Aurora PostgreSQL Multi-AZ :** Garantit le respect absolu d'ACID pour chaque centime transféré, avec isolation par snapshot et basculement automatique sans perte de données.
- **Intégration & Streaming — Debezium CDC + Amazon MSK :** La capture des modifications (CDC) lit le journal des transactions (WAL) d'Aurora de manière totalement asynchrone, évitant toute contention sur la base de production. Kafka distribue les flux vers l'OLAP et le Data Lake.
- **OLAP — Amazon Redshift Serverless :** Architecture en étoile (Star Schema) orientée colonnes, offrant des performances d'agrégation massives pour la BI tout en s'adaptant à la demande sans surcoût d'inactivité.
- **NoSQL — Amazon DocumentDB (compatible MongoDB) :** Structure documentaire JSON flexible pour capturer la télémétrie matérielle et les micro-interactions sans imposer de schéma rigide.

- **Feature Store & IA — Feast sur Redis ElastiCache :** Assure la parité stricte entre les features calculées hors-ligne pour l'entraînement et celles servies en moins de 5 ms lors de l'inférence temps réel.

---

4. Structure du Dossier de Certification

Ce dossier contient l'ensemble des 8 livrables techniques détaillés, complétés par le code d'Infrastructure as Code (Terraform) validé et le script de soutenance orale :

- **Livrable 01 :** Schéma d'Architecture Globale (Logique & Physique AWS Multi-AZ).
- **Livrable 02 :** Modèle Relationnel Transactionnel Normalisé (OLTP 3NF ACID).
- **Livrable 03 :** Schéma Analytique Décisionnel en Étoile (OLAP Star Schema).
- **Livrable 04 :** Modélisation Semi-Structurée Documentaire (NoSQL MongoDB).
- **Livrable 05 :** Architecture des Pipelines de Données (ETL, ELT, CDC & Streaming).
- **Livrable 06 :** Plan de Sécurité, Conformité (PCI-DSS / RGPD) & FinOps / GreenOps.
- **Livrable 07 :** Stratégie d'Intégration Machine Learning & Budget de Latence < 100 ms.
- **Livrable 08 :** Requêtes d'Analyse Métier SQL (OLAP) & NoSQL (Agrégations).
- **IaC Terraform :** Module de déploiement automatisé avec preuve d'idempotence et reproductibilité.
- **Synthèse Exécutive :** Présentation synthétique des choix d'architecture et de dimensionnement.