STRIPE AI INFRASTRUCTURE • CERTIFICATION BLOC 2 (RNCP 41993)

Modèle Documentaire NoSQL — Télémétrie, Empreintes & Événements

Tandis que le système financier (OLTP) exige un schéma relationnel rigide et des verrous transactionnels ACID, les données de télémétrie présentent des caractéristiques radicalement différentes : 1. **Schéma Hautement Polymorphe & Évolutif :** Un navigateur web de bureau renvoie des attributs WebGL, polices installées et mouvements de souris, alors qu'une application iOS native renvoie des métriques d'accéléromètre, état de batterie et version de Secure Enclave. Tenter d'aplatir ces données dans des tables SQL mènerait à des tables avec des dizaines de colonnes `NULL` ou à des jointures EAV (*Entity-Attribute-Value*) ingérables. 2. **Débit d'Écriture Massif & Asynchrone :** Chaque tentative de paiement génère des dizaines de micro-événements (frappes clavier, temps de focalisation, changements d'onglets). Le moteur NoSQL (MongoDB WiredTiger) absorbe des dizaines de milliers d'insertions par seconde sans impacter les verrous de la base transactionnelle. 3. **Accès par Clé Unitaire en Temps Réel (< 10 ms) :** Le modèle documentaire permet de lire en une seule opération disque (`findOne`) la totalité du contexte matériel d'un appareil à partir de son empreinte cryptographique.

2. Stratégie de Modélisation : *Embedding* vs *Referencing*

Le choix entre intégration imbriquée (*Embedding*) et liaison par référence (*Referencing*) respecte les règles d'or de l'ingénierie NoSQL :

Critère d'Arbitrage	Approche Adoptée	Justification Technique & Métier
Sous-documents bornés & consultés ensemble (ex: attributs matériels, coordonnées GPS, métriques de vélocité)	**Embedding (Imbrication)**	La télémétrie matérielle (`hardware_telemetry`) fait corps avec l'empreinte. En l'imbriquant dans le document parent, une seule lecture physique ramène toutes les métriques nécessaires au modèle d'IA, évitant toute jointure ($O(1)$ disk seek).
Historique chronologique court (ex: les 10 dernières adresses IP vues, tentatives de webhook)	**Embedding (Tableaux d'objets)**	La taille du tableau reste modeste (< 100 éléments), bien en-deçà de la limite BSON de 16 Mo. Le document reste compact et rapide à sérialiser.
Entités indépendantes à cardinalité infinie (ex: Marchand ↔ Événements, Client ↔ Empreintes multiples)	**Referencing (Liaison par ID)**	On stocke uniquement les identifiants `merchant_id` et `customer_id` . Cela évite la saturation de mémoire du document et garantit l'indépendance du cycle de vie des entités.

3. Collections Détaillées & Exemples de Documents BSON / JSON

3.1. Collection `device_fingerprints` (Télémétrie Matérielle & Détection de Bots)

Cette collection enregistre l'identité cryptographique des terminaux payeurs. Elle alimente directement le microservice Radar pour identifier les attaques automatisées par force brute ou émulateurs headless :


```
{
  "_id": "fp_982a7b8c12e5",
  "fingerprint_hash": "e3b0c44298fc1c149afbf4c8996fb92427ae41e4649b934ca495991b7852b855",
  "customer_id": "cus_9s8f72aK",
  "first_seen": "2026-08-15T14:20:00Z",
  "last_seen": "2026-09-06T20:15:30Z",
  "hardware_telemetry": {
    "user_agent": "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7) AppleWebKit/537.36",
    "screen_resolution": "2560x1440",
    "color_depth": 24,
    "timezone_offset": -120,
    "cpu_cores": 8,
    "device_memory_gb": 16,
    "canvas_hash": "a1b2c3d4e5f6",
    "webgl_vendor": "Apple Inc.",
    "webgl_renderer": "Apple M2 Pro",
    "audio_fingerprint_hash": "7f8e9d0c1b2a",
    "touch_support": false
  },
  "bot_indicators": {
    "is_webdriver_present": false,
    "is_headless": false,
    "has_inconsistent_fonts": false,
    "stealth_eval_detected": false
  },
  "ip_addresses": [
    { "ip": "82.65.120.44", "country": "FR", "asn": "AS12322 Free SAS", "seen_count": 42, "last_us
    { "ip": "176.150.12.8", "country": "FR", "asn": "AS3215 Orange", "seen_count": 5, "last_used":
  ],
  "velocity_metrics": {
    "cards_associated_count": 2,
    "merchants_visited_24h": 4,
    "txns_attempted_1h": 1
  }
}
```


3.2. Collection `clickstream_events` (Parcours d'Achat & Dynamique de Saisie)

Capture la dynamique comportementale de l'utilisateur sur la page de paiement. Les fraudeurs humains et scripts de scraping présentent des dynamiques de frappe (*keystroke dynamics*) très distinctes d'un client légitime :

```
{
  "_id": "clk_501a9bf1c",
  "checkout_session_id": "cs_test_a1b2c3d4e5f6g7h8",
  "merchant_id": "acct_1H2X92jks92",
  "customer_ip": "194.250.35.12",
  "timestamp": "2026-09-06T20:14:50Z",
  "duration_on_page_ms": 38400,
  "form_interaction": {
    "card_number_paste_used": true,
    "cvv_typing_duration_ms": 620,
    "mouse_entropy_score": 0.89,
    "tab_switches_count": 1
  },
  "journey_steps": [
    { "step": "page_view", "url": "/checkout/pay", "dwell_time_ms": 5200 },
    { "step": "fill_shipping_address", "country": "FR", "dwell_time_ms": 14500 },
    { "step": "enter_card_details", "dwell_time_ms": 12800 },
    { "step": "submit_click", "button_id": "btn-pay-now", "dwell_time_ms": 5900 }
  ],
  "risk_evaluation": {
    "behavioral_bot_score": 0.04,
    "fraud_pattern_matched": "standard_human_checkout"
  }
}
```


3.3. Collection `webhook_delivery_logs` (Journalisation des Événements Marchands)

Consigne les notifications asynchrones transmises aux serveurs marchands (confirmation de paiement, litige, remboursement). L'historique des tentatives (*retries*) est imbriqué pour auditer les défaillances réseau :

```
{
  "_id": "whl_897123aa",
  "event_id": "evt_1M7q3p2eZvKYlo2CL8",
  "merchant_id": "acct_1H2X92jks92",
  "event_type": "payment_intent.succeeded",
  "endpoint_url": "https://api.merchantstore.com/webhooks/stripe",
  "created_at": "2026-09-06T20:15:35Z",
  "delivery_status": "succeeded",
  "attempts": [
    {
      "attempt_number": 1,
      "timestamp": "2026-09-06T20:15:35.120Z",
      "http_status": 504,
      "latency_ms": 5012,
      "error_message": "Gateway Timeout"
    },
    {
      "attempt_number": 2,
      "timestamp": "2026-09-06T20:15:40.350Z",
      "http_status": 200,
      "latency_ms": 142,
      "error_message": null
    }
  ]
}
```


4. Stratégie d'Indexation & Cycle de Vie des Données (TTL Indexes)

Pour assurer des requêtes instantanées et une maîtrise stricte des coûts de stockage, les index suivants sont déployés :

1. **Index d'Unicité Rapide :** `javascript db.device_fingerprints.createIndex({ "fingerprint_hash": 1 }, { unique: true });` *Garantit une recherche en O(1) de l'historique d'un appareil lors de l'inférence temps réel.*
2. **Index Composé Temporel :** `javascript db.clickstream_events.createIndex({ "merchant_id": 1, "timestamp": -1 });` *Accélère l'analyse des sessions suspectes sur un marchand spécifique au cours de la dernière heure.*
3. **Index TTL (Time-To-Live) de Purge Automatique (Conformité RGPD & FinOps) :** `javascript db.webhook_delivery_logs.createIndex( { "created_at": 1 }, { expireAfterSeconds: 7776000 } // 90 jours );` *Supprime automatiquement les logs techniques après 90 jours. Respecte le principe de minimisation RGPD et évite l'explosion des factures de stockage disque sans nécessiter de script cron de maintenance.*