STRIPE AI INFRASTRUCTURE • CERTIFICATION BLOC 2 (RNCP 41993)

Modèle Documentaire NoSQL — Multi-Formats, Télémétrie, Retours Clients & Vecteurs ML

Tandis que le système financier (OLTP) exige un schéma relationnel rigide et des verrous transactionnels ACID, les données non structurées et semi-structurées de Stripe présentent des caractéristiques radicalement différentes : 1. **Schéma Hautement Polymorphe & Évolutif :** Un navigateur web de bureau renvoie des attributs WebGL et mouvements de souris, une application iOS native renvoie des métriques d'accéléromètre, et les partenaires bancaires émettent des notifications **XML ISO 20022** hétérogènes. Tenter d'aplatir ces données dans des tables SQL mènerait à des dizaines de colonnes `NULL` ou à des jointures EAV (*Entity-Attribute-Value*) ingérables. 2. **Prise en Charge Multi-Formats (JSON, XML & Données Binaires) :** Amazon DocumentDB (compatible MongoDB) stocke nativement le **JSON/BSON**, encapsule les messages **XML bancaires/SEPA** normalisés avec conservation du payload brut et métadonnées XPath indexées, et associe les **données binaires** (justificatifs de litiges PDF, captures biométriques chiffrées, blobs compressés zlib via type BSON `BinData` < 16 Mo ou pointeur chiffré S3 pour les pièces jointes volumineuses). 3. **Débit d'Écriture Massif & Accès en < 10 ms :** Le moteur NoSQL absorbe des dizaines de milliers d'insertions asynchrones par seconde sans verrouiller l'OLTP, tout en permettant une lecture unitaire en $O(1)$ (`findOne`) lors du scoring temps réel.

2. Stratégie de Modélisation : *Embedding* vs *Referencing*

Le choix entre intégration imbriquée (*Embedding*) et liaison par référence (*Referencing*) respecte les règles d'or de l'ingénierie NoSQL :

Critère d'Arbitrage	Approche Adoptée	Justification Technique & Métier
Sous-documents bornés & consultés ensemble (ex: attributs matériels, coordonnées GPS, vecteurs ML)	**Embedding (Imbrication)**	La télémétrie matérielle (`hardware_telemetry`) fait corps avec l'empreinte. En l'imbriquant dans le document parent, une seule lecture physique ramène toutes les métriques nécessaires au modèle d'IA sans jointure ($O(1)$ disk seek).
Historique chronologique court (ex: les 10 dernières adresses IP vues, tentatives de webhook)	**Embedding (Tableaux d'objets)**	La taille du tableau reste bornée (< 100 éléments), bien en-deçà de la limite BSON de 16 Mo. Le document reste compact et rapide à sérialiser.
Entités indépendantes à cardinalité infinie (ex: Marchand ↔ Événements, Client ↔ Avis/Paiements)	**Referencing (Liaison par ID)**	On conserve uniquement les identifiants immuables `merchant_id` , `customer_id` et `transaction_id` afin d'éviter la saturation BSON et de faciliter le pont analytique avec Aurora OLTP et Redshift OLAP.

3. Collections Détaillées & Exemples de Documents BSON / JSON

3.1. Collection `device_fingerprints` (Télémétrie Matérielle & Détection de Bots)

Enregistre l'identité cryptographique des terminaux payeurs et alimente le moteur **Stripe Radar** :


```
{
  "_id": "fp_982a7b8c12e5",
  "fingerprint_hash": "e3b0c44298fc1c149afbf4c8996fb92427ae41e4649b934ca495991b7852b855",
  "customer_id": "cus_9s8f72aK",
  "first_seen": "2026-08-15T14:20:00Z",
  "last_seen": "2026-11-12T20:15:30Z",
  "hardware_telemetry": {
    "user_agent": "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7) AppleWebKit/537.36",
    "screen_resolution": "2560x1440",
    "color_depth": 24,
    "timezone_offset": -120,
    "cpu_cores": 8,
    "device_memory_gb": 16,
    "canvas_hash": "a1b2c3d4e5f6",
    "webgl_vendor": "Apple Inc.",
    "webgl_renderer": "Apple M2 Pro",
    "touch_support": false
  },
  "bot_indicators": {
    "is_webdriver_present": false,
    "is_headless": false,
    "has_inconsistent_fonts": false
  },
  "ip_addresses": [
    { "ip": "82.65.120.44", "country": "FR", "asn": "AS12322 Free SAS", "seen_count": 42, "last_us
  ],
  "velocity_metrics": {
    "cards_associated_count": 2,
    "merchants_visited_24h": 4,
    "txns_attempted_1h": 1
  }
}
```


3.2. Collection `clickstream_events` (Parcours d'Achat & Personnalisation Checkout)

Capture la dynamique comportementale sur les pages de paiement (détection de bots par vitesse de frappe et signal d'intention pour la personnalisation **Adaptive Checkout**) :

```
{
  "_id": "clk_501a9bf1c",
  "checkout_session_id": "cs_live_a1b2c3d4e5f6g7h8",
  "merchant_id": "acct_1H2X92jks92",
  "customer_id": "cus_9s8f72aK",
  "customer_ip": "194.250.35.12",
  "timestamp": "2026-11-12T20:14:50Z",
  "duration_on_page_ms": 38400,
  "form_interaction": {
    "card_number_paste_used": true,
    "cvv_typing_duration_ms": 620,
    "mouse_entropy_score": 0.89,
    "tab_switches_count": 1
  },
  "journey_steps": [
    { "step": "page_view", "url": "/checkout/pay", "dwell_time_ms": 5200 },
    { "step": "select_payment_method", "recommended_order": ["apple_pay", "card", "sepa_debit"], "
    { "step": "submit_click", "button_id": "btn-pay-now", "dwell_time_ms": 5900 }
  ],
  "risk_evaluation": {
    "behavioral_bot_score": 0.04,
    "fraud_pattern_matched": "standard_human_checkout"
  }
}
```


3.3. Collection `webhook_delivery_logs` (Logs Multi-Formats JSON, XML ISO 20022 & Pièces Binaires)

Consigne les journaux d'appels API, les accusés bancaires **XML ISO 20022** (`camt.054` / `pain.002`) et les justificatifs **binaires** associés aux contestations :

```
{
  "_id": "whl_897123aa",
  "event_id": "evt_1M7q3p2eZvKYlo2CL8",
  "merchant_id": "acct_1H2X92jks92",
  "transaction_id": "txn_3M7q91xZ",
  "payload_format": "JSON_AND_XML_REF",
  "event_type": "payment_intent.succeeded",
  "endpoint_url": "https://api.merchantstore.com/webhooks/stripe",
  "created_at": "2026-11-12T20:15:35Z",
  "delivery_status": "succeeded",
  "attempts": [
    { "attempt_number": 1, "timestamp": "2026-11-12T20:15:35.120Z", "http_status": 504, "latency_m
    { "attempt_number": 2, "timestamp": "2026-11-12T20:15:40.350Z", "http_status": 200, "latency_m
  ],
  "banking_settlement_xml": {
    "standard": "ISO_20022_camt_054",
    "end_to_end_id": "E2E-FR-9928174",
    "raw_xml_compressed_bin": { "$binary": { "base64": "H4sIAAAAAAAA...", "subType": "00" } }
  },
  "binary_evidence_ref": {
    "receipt_pdf_s3_uri": "s3://stripe-eu-west-3-evidence-encrypted/2026/11/txn_3M7q91xZ.pdf",
    "sha256_checksum": "9f86d081884c7d659a2feaa0c55ad015a3bf4f1b2b0b822cd15d6c15b0f00a08",
    "content_type": "application/pdf"
  }
}
```

3.4. Collection `customer_feedback` (Retours Clients, Avis & Sondages NPS)

Stocke les retours textuels non structurés (avis marchands, commentaires après litige, sondages de satisfaction produit) enrichis par pipeline NLP pour détecter précocement les signes d'attrition (*Churn*) :

```
{
  "_id": "fbk_7741a2b9",
  "merchant_id": "acct_1H2X92jks92",
  "customer_id": "cus_9s8f72aK",
  "country": "FR",
  "channel": "in_app_survey",
  "created_at": "2026-11-12T18:10:00Z",
  "nps_score": 4,
  "csat_rating": 2,
  "raw_comment": "Trop de refus 3D-Secure sur les paiements mobiles au moment du renouvellement d'
  "nlp_enrichment": {
    "language": "fr",
    "sentiment_score": -0.68,
    "detected_topics": ["3ds_friction", "subscription_renewal", "mobile_checkout"],
    "churn_risk_signal": "high"
  },
  "ccpa_opt_out": false
}
```

3.5. Collection `ml_feature_vectors` (Caractéristiques Machine Learning & Traçabilité)

Persiste directement au sein de la base NoSQL les vecteurs de caractéristiques calculés et le contexte d'explicabilité (**SHAP values**) utilisés par nos trois moteurs IA (Fraude Radar, Adaptive Checkout et Smart Retries) :


```
{
  "_id": "mlfv_txn_3M7q91xZ",
  "entity_type": "transaction_scoring",
  "transaction_id": "txn_3M7q91xZ",
  "merchant_id": "acct_1H2X92jks92",
  "customer_id": "cus_9s8f72aK",
  "computed_at": "2026-11-12T20:15:29.880Z",
  "model_references": {
    "fraud_model": "radar_xgb_v2.4.1",
    "checkout_recommender": "adaptive_ctx_bandit_v1.8"
  },
  "dense_features": {
    "velocity_1h_card": 1,
    "avg_ticket_30d_ratio": 1.15,
    "ip_to_card_distance_km": 4.2,
    "device_bot_score": 0.04,
    "merchant_churn_propensity": 0.12
  },
  "embedding_vector_16d": [0.12, -0.45, 0.88, 0.03, -0.21, 0.67, 0.14, -0.09, 0.31, -0.52, 0.08, 0
  "explainability_top_drivers": [
    { "feature": "device_bot_score", "shap_contribution": -0.41 },
    { "feature": "ip_to_card_distance_km", "shap_contribution": -0.22 }
  ]
}
```


---

4. Stratégie d'Indexation & Cycle de Vie des Données (TTL Indexes)

Pour assurer des requêtes instantanées et une maîtrise stricte des coûts de stockage :

1. **Index d'Unicité Rapide :** `javascript db.device_fingerprints.createIndex({ "fingerprint_hash": 1 }, { unique: true });` *Garantit une recherche en $O(1)$ de l'historique d'un appareil lors de l'inférence temps réel.*

2. **Index Composés Temporels & Métiers :** `javascript db.clickstream_events.createIndex({ "merchant_id": 1, "timestamp": -1 }); db.customer_feedback.createIndex({ "merchant_id": 1, "nlp_enrichment.churn_risk_signal": 1, "created_at": -1 }); db.ml_feature_vectors.createIndex({ "transaction_id": 1 }, { unique: true });`

3. **Index TTL (Time-To-Live) de Purge Automatique (RGPD, CCPA & FinOps) :** `javascript db.webhook_delivery_logs.createIndex( { "created_at": 1 }, { expireAfterSeconds: 7776000 } // Purge automatique à 90 jours );` *Respecte la minimisation RGPD/CCPA et maîtrise la facture disque sans script cron.*

---

5. Stratégie d'Intégration Polyglotte (Pont NoSQL ↔ OLTP ↔ OLAP)

L'un des défis clés de Stripe est de corréler les données NoSQL avec les transactions financières (OLTP) et le décisionnel (OLAP) sans jamais effectuer de jointure applicative coûteuse en temps réel :

1. **Clés d'Identité Transverses (*Golden Bridge Keys*) :**
   Tous les documents DocumentDB portent explicitement les identifiants immuables générés par l'écosystème transactionnel : `merchant_id`, `customer_id`, `transaction_id` et `checkout_session_id`.
2. **Synchronisation Asynchrone via Change Streams & Kafka MSK :**
   Le connecteur **Kafka Connect Mongo Source** écoute les *Change Streams* de DocumentDB et diffuse les événements (`clickstream`, `feedback`, `ml_feature_vectors`) vers Kafka MSK (`stripe.telemetry.v1`).
3. **Fusion vers OLAP & Feature Store :**
4. **Flux Chaud :** Apache Flink croise en temps réel les flux `stripe.txns.v1` (issus d'Aurora via Debezium CDC) et `stripe.telemetry.v1` (issus de DocumentDB) sur une fenêtre glissante par `customer_id` pour alimenter **Feast/Redis**.
5. **Flux Analytique (Batch / Micro-Batch) :** Les signaux agrégés NoSQL (taux d'avis négatifs, score de friction mobile, latence webhooks) sont injectés vers S3 Gold et Redshift afin d'enrichir `DimMerchant` et `DimCustomer` sans exposer le JSON brut aux outils BI.