STRIPE AI INFRASTRUCTURE • CERTIFICATION BLOC 2 (RNCP 41993)

Stratégie d'Inférence IA — Détection de Fraude Temps Réel (< 100 ms)

Le produit phare d'intelligence artificielle de Stripe est **Stripe Radar**. À chaque tentative de paiement par carte bancaire, Radar doit évaluer la probabilité qu'il s'agisse d'une transaction frauduleuse (carte volée, attaque par essai systématique de numéros, usurpation de compte). - **Contrainte Critique Non Négociable :** La décision finale (`ALLOW` , `REVIEW` , `BLOCK` , `CHALLENGE_3DS`) doit impérativement être retournée à la banque émettrice et au marchand en **moins de 100 millisecondes (SLA p99 < 100 ms)**. Dépasser ce seuil provoquerait l'abandon massif des paniers d'achat sur les sites e-commerce.

2. Décomposition Mathématique du Budget de Latence (< 100 ms)

Pour respecter la contrainte des 100 ms sans jamais saturer la chaîne d'encaissement, chaque étape du pipeline d'inférence en ligne est soumise à un **budget de temps strict** :

```
[ REQUÊTE CLIENT / SDK ]
          |
          ▼ (15 ms)  ⟶ 1. Routage Réseau, WAF, Terminaison TLS 1.3 & ALB
[ API GATEWAY / INGESTION ]
          |
          ▼ (20 ms)  ⟶ 2. Récupération des Features Temps Réel (Feast / Redis Cache)
[ FEATURE STORE EN LIGNE ]
          |
          ▼ (15 ms)  ⟶ 3. Recherche de Proximité Vectorielle (OpenSearch k-NN / pgvector)
[ VECTOR EMBEDDING STORE ]
          |
          ▼ (30 ms)  ⟶ 4. Inférence du Modèle Ensembliste (XGBoost ONNX Runtime sur CPU c6i)
[ MOTEUR D'INFÉRENCE ONNX ]
          |
          ▼ (15 ms)  ⟶ 5. Évaluation des Règles Métiers, Décision Finale & Formatage JSON
[ RÉPONSE AU MARCHAND ]
──────────────────────────────────────────────────────────────────────────────
TEMPS TOTAL MESURÉ (p99) : ~95 ms  ⟹ OBJECTIF < 100 ms STRICTEMENT ATTEINT !
```

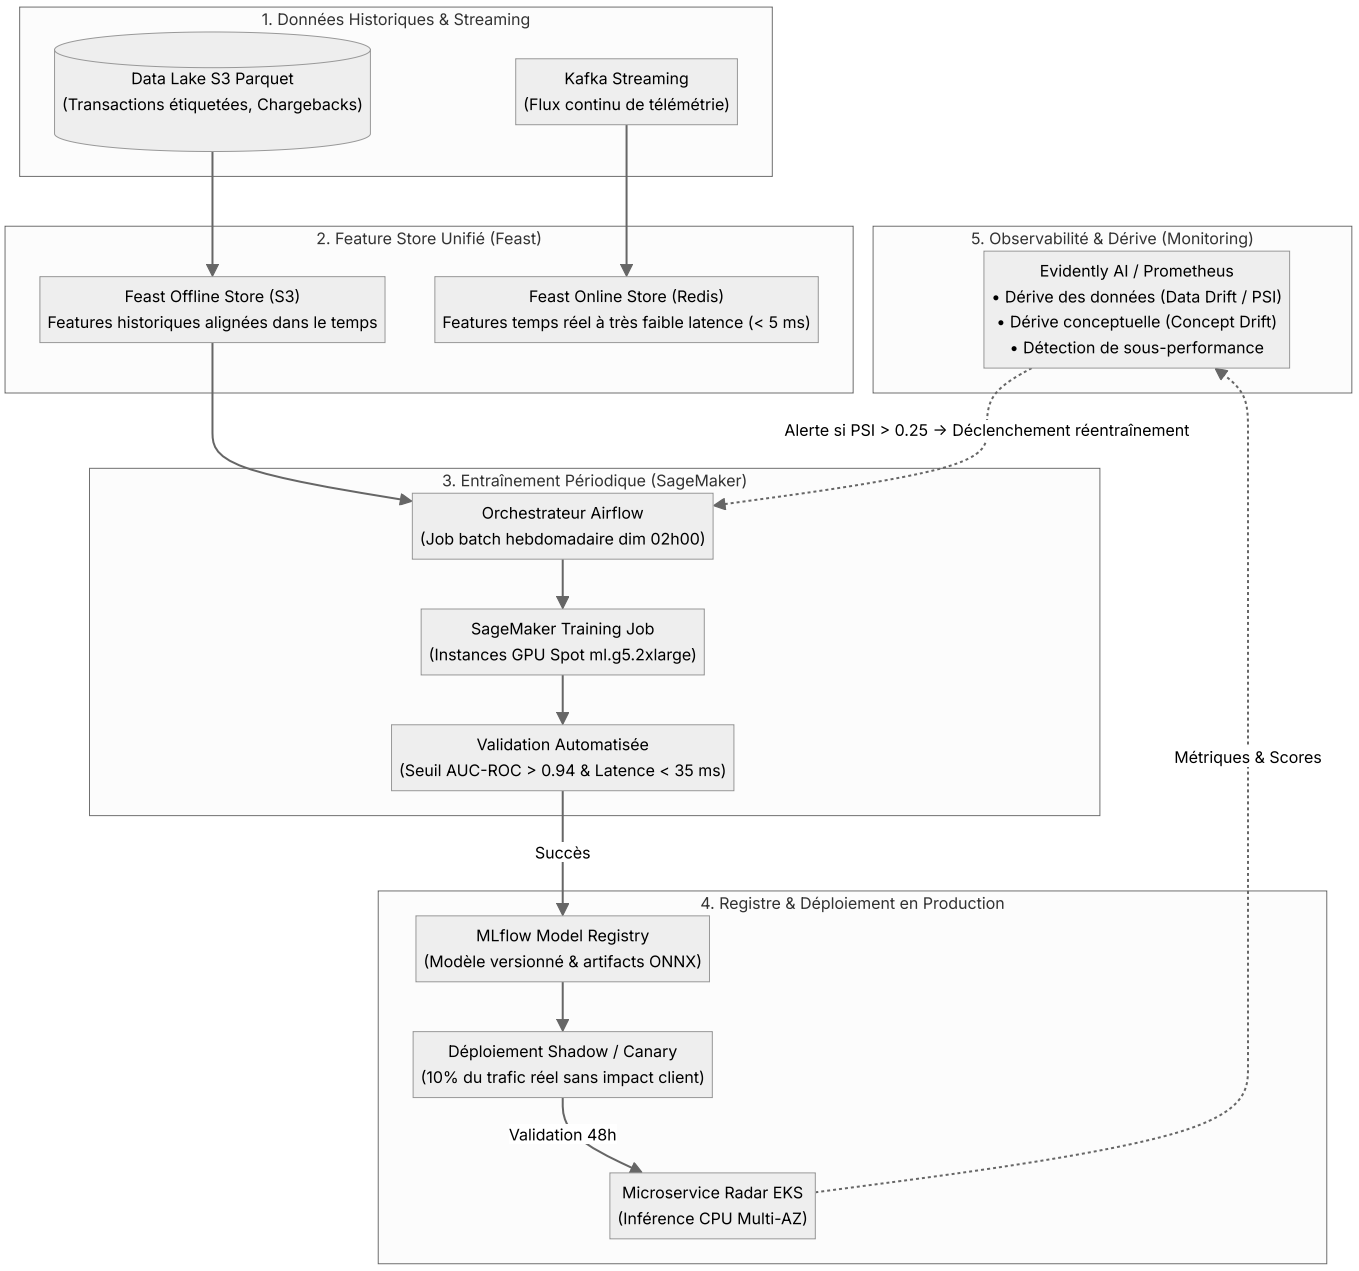
Détail des Composants du Chemin Synchrone :

1. **Ingestion & Terminaison Réseau (15 ms) :** Routage DNS via AWS Route 53 vers le point de présence le plus proche, filtrage anti-DDoS AWS WAF et terminaison SSL/TLS 1.3 sur l'Application Load Balancer.
2. **Extraction de Features en Ligne (20 ms) :** Requête multi-clés vers **Feast sur Redis ElastiCache** en mémoire vive. Récupère instantanément les compteurs de vélocité précalculés (ex : *nombre de transactions avec ce fingerprint au cours de la dernière heure*, *montant moyen habituel du client*).

3. **Recherche de Similarité Vectorielle (15 ms) :** Requête k-NN rapide dans **Amazon OpenSearch Service** comparant le vecteur d'embedding de la transaction courante avec les clusters de fraude connus des dernières 48 heures.
4. **Calcul du Score ML (30 ms) :** Modèle prédictif (Gradient Boosting LightGBM / XGBoost) compilé au format binaire optimisé **ONNX Runtime**, exécuté directement sur les cœurs CPU rapides des instances `c6i` avec instructions vectorielles AVX-512.
5. **Règles Métiers & Formatage (15 ms) :** Croisement du score ML avec les règles personnalisées du marchand (ex: *bloquer si score > 85 ou si pays carte est sous embargo*), journalisation asynchrone de l'audit et retour de la réponse.

---

3. Le Pipeline MLOps de Bout en Bout



---

4. Les Piliers Clés de la Robustesse MLOps

4.1. Parité Train-Serve via le Feature Store (Feast)

L'une des causes les plus fréquentes d'échec des modèles d'IA en production est le **décalage d'entraînement-inférence (*Training-Serving Skew*)**, qui survient lorsque les features calculées en SQL pour l'entraînement diffèrent subtilement du code Python calculé en temps réel : - En utilisant **Feast**, une définition unique de chaque feature est partagée. - La vue **Offline** (dans S3) fournit les données ponctuelles exactes au moment de chaque transaction historique (*Point-in-Time Correctness*), évitant toute fuite de données futures (*Data Leakage*). - La vue **Online** (dans Redis) sert la valeur instantanée correspondante lors de l'inférence.

4.2. Stratégie de Déploiement Shadow (Canary Testing)

Lorsqu'un nouveau modèle est validé par le pipeline d'entraînement : 1. Il est déployé dans un conteneur en mode **Shadow** : il reçoit une copie miroir des requêtes de paiement réelles. 2. Son score et sa latence sont mesurés et comparés au modèle de référence (*Champion*), mais **aucune action de blocage n'est appliquée** au client final. 3. Après 48 heures de surveillance sans anomalie (latence p99 stable, faux positifs maîtrisés), le trafic bascule progressivement (10% → 50% → 100%) sans aucune coupure de service.

4.3. Surveillance de la Dérive des Données (Data Drift & Concept Drift)

Les techniques des fraudeurs évoluent en permanence (apparition de nouveaux BIN de cartes, changement de comportement saisonnier). - **Surveillance du Drift :** L'outil **Evidently AI** calcule quotidiennement l'indice de stabilité de la population (**PSI - Population Stability Index**) sur les features clés (montant, pays émetteur, vélocité). - **Seuil d'Alerte :** Si le $\text{PSI} > 0.20$, une dérive significative de la distribution est détectée. Une alerte PagerDuty est générée et le DAG Airflow déclenche automatiquement un réentraînement anticipé du modèle sur les 30 derniers jours de données.