STRIPE AI INFRASTRUCTURE • CERTIFICATION BLOC 2 (RNCP 41993)

Stratégie d'Intégration Machine Learning — NoSQL, Inférence Temps Réel, Personnalisation & Analyse Prédictive

L'infrastructure Data & NoSQL de Stripe alimente **trois familles de cas d'usage d'Intelligence Artificielle**, réparties entre exécution synchrone temps réel (< 100 ms) et apprentissage/scoring prédictif piloté par les flux streaming et batch :

1. **Détection de Fraude en Temps Réel (`Stripe Radar` — SLA < 100 ms) :** Blocage ou défi 3D-Secure instantané lors de la tentative de paiement (`ALLOW` , `REVIEW` , `BLOCK` , `CHALLENGE_3DS`).
2. **Personnalisation Client & Recommandations en Temps Réel (`Adaptive Checkout`) :** Sélection dynamique et classement des moyens de paiement les plus pertinents selon le contexte appareil/clickstream NoSQL pour maximiser la conversion.
3. **Analyse Prédictive (`Smart Retries` & Prédiction d'Attrition / Churn) :** Optimisation ML du calendrier de relance des paiements d'abonnements échoués et alerte précoce de risque de départ marchand.

2. Intégration Architecturale des Modèles ML au Système NoSQL (DocumentDB)

Contrairement aux modèles tabulaires classiques ne lisant que des bases SQL, les signaux comportementaux les plus discriminants de Stripe résident dans la base documentaire NoSQL (**Amazon DocumentDB**) :

- **Ingestion de Caractéristiques Semi-Structurées (Lecture Rapide $O(1)$) :** Lorsqu'une session s'ouvre, le microservice ML interroge en parallèle `device_fingerprints` (indicateurs headless/WebGL/IP), `clickstream_events` (entropie souris, temps de saisie CVV, parcours pages) et `customer_feedback` (score de sentiment NLP).
- **Pont vers le Feature Store Temps Réel (Feast / Redis) :** Les attributs JSON bruts de DocumentDB sont transformés en continu par **Apache Flink** (calcul des ratios de vélocité, distances géographiques et scores agrégés) puis poussés dans **Feast Online Store (Redis)** pour un accès en mémoire vive en `< 5 ms` .
- **Persistance Bidirectionnelle (`ml_feature_vectors`) :** Chaque décision d'inférence écrit de manière asynchrone le vecteur exact des caractéristiques utilisées, le score émis et les contributions d'explicabilité (**SHAP values**) dans la collection DocumentDB `ml_feature_vectors` . Cela garantit à la fois la **reproductibilité des audits IA Act** et la matière brute pour le réentraînement batch sans coût de recalcul.

3. Les 3 Cas d'Usage d'Intelligence Artificielle Déployés

3.1. Cas d'Usage 1 : Détection de Fraude en Temps Réel (`Stripe Radar` — Budget < 100 ms)

Dépasser 100 millisecondes au 99e percentile provoquerait des abandons de panier. Chaque étape du chemin synchrone respecte un **budget mathématique strict** :

```
[ REQUÊTE CLIENT / SDK ]
          |
          ▼ (15 ms)  ⟶ 1. Routage Réseau, WAF, Terminaison TLS 1.3 & ALB
[ API GATEWAY / INGESTION ]
          |
          ▼ (20 ms)  ⟶ 2. Récupération des Features Temps Réel (Feast Redis + contexte DocumentD
[ FEATURE STORE EN LIGNE ]
          |
          ▼ (15 ms)  ⟶ 3. Recherche de Proximité Vectorielle (OpenSearch k-NN sur motifs 48h)
[ VECTOR EMBEDDING STORE ]
          |
          ▼ (30 ms)  ⟶ 4. Inférence Ensembliste (XGBoost ONNX Runtime sur CPU c6i AVX-512)
[ MOTEUR D'INFÉRENCE ONNX ]
          |
          ▼ (15 ms)  ⟶ 5. Règles Métiers Marchand, Décision Finale & Formatage JSON
[ RÉPONSE AU MARCHAND ]
_____________________________________________________________________________

TEMPS TOTAL MESURÉ (p99) : ~95 ms  ⟹ OBJECTIF SLA < 100 ms STRICTEMENT ATTEINT !
```

- **Arbitrage CPU vs GPU :** Pour un scoring unitaire (`batch_size = 1`), le transfert mémoire CPU↔GPU via bus PCIe ajoute ~10-15 ms de latence et coûte 5× plus cher. L'exécution **ONNX Runtime en C++ sur CPU** `c6i` avec instructions vectorielles AVX-512 offre 30 ms déterministes et une résilience d'auto-scaling Kubernetes immédiate.

3.2. Cas d'Usage 2 : Personnalisation Client & Recommandations en Temps Réel (`Adaptive Checkout`)

- **Problématique Métier :** Proposer 15 moyens de paiement sur un petit écran mobile fait chuter la conversion ; proposer un moyen non utilisé dans le pays du client (ex: *iDEAL* aux Pays-Bas vs *Carte/Apple Pay* en France) augmente l'abandon.
- **Intégration ML ↔ NoSQL :** Un modèle contextuel (*Contextual Multi-Armed Bandit* / LightGBM déployé sur le même cluster EKS) croise en `< 25 ms` l'historique NoSQL (`clickstream_events` , type d'appareil, navigateur Safari/Chrome, panier et drapeau CCPA `do_not_sell_or_share`) pour ordonner dynamiquement la liste des méthodes de paiement proposées dès l'affichage du formulaire.
- **Garde-fou Réglementaire :** Si l'utilisateur californien a activé l'*Opt-Out* CCPA, le modèle bascule en mode contextuel pur (langue navigateur + devise uniquement) sans exploiter l'historique comportemental personnel.

3.3. Cas d'Usage 3 : Analyse Prédictive (`Smart Retries` & Prédiction d'Attrition / Churn)

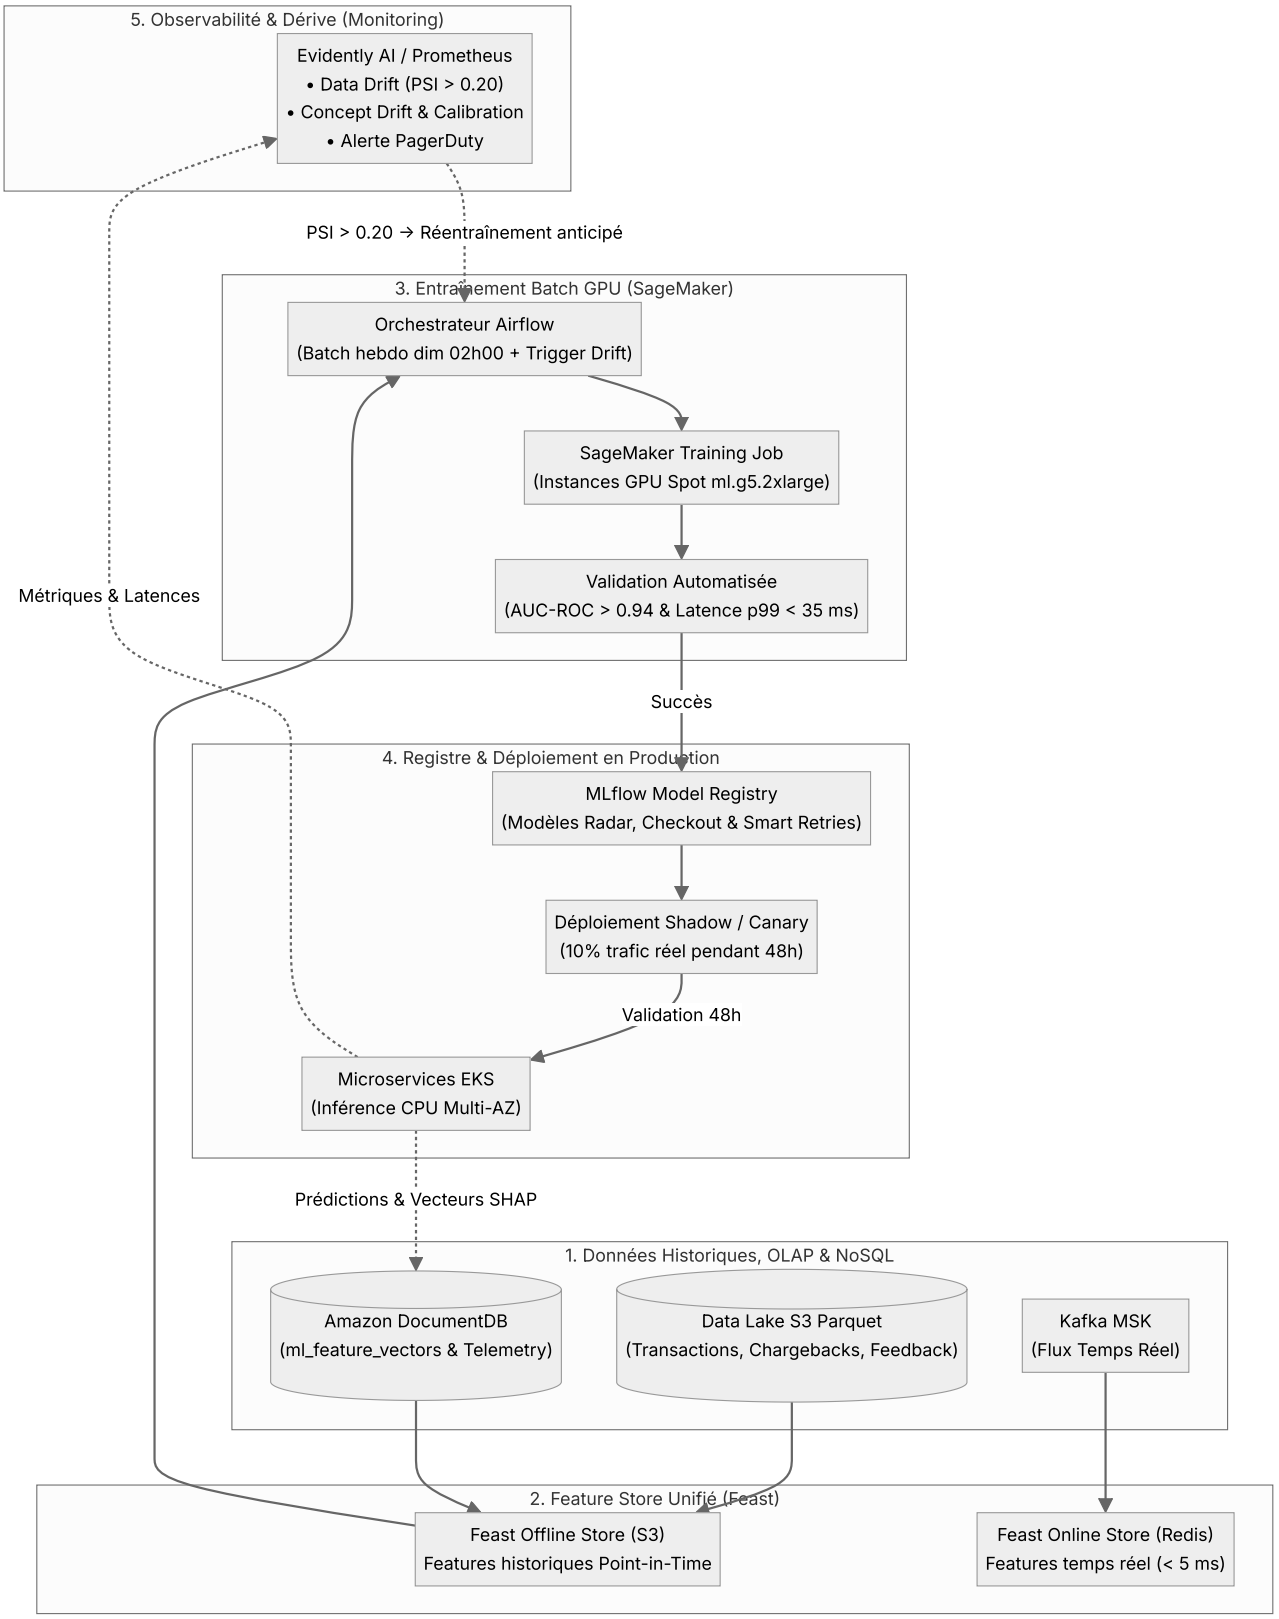
- **Optimisation Prédictive des Abonnements (`Smart Retries`) :** Lorsqu'un prélèvement récurrent (`Subscription`) échoue pour `insufficient_funds` ou refus temporaire bancaire, relancer à heure fixe

échoue dans > 70% des cas. Un modèle prédictif entraîné en batch sur **Amazon SageMaker** (historique S3 Gold + séries temporelles bancaires + logs NoSQL `webhook_delivery_logs`) prédit la **fenêtre horaire optimale** de recouvrement (ex: lendemain du versement des salaires / ouverture du cycle bancaire local) et programme automatiquement la tentative.

- **Détection Précoce du Churn Marchand :** Fusionne la baisse tendancielle du GPV (OLAP Redshift) avec les signaux faibles NoSQL (`customer_feedback` négatifs en NLP + pics de latence 5xx dans `webhook_delivery_logs`) pour scorer hebdomadairement le risque d'attrition de chaque marchand et alerter les *Account Managers*.

---

4. Le Pipeline MLOps de Bout en Bout (Réentraînement, Déploiement & Drift)



Piliers de Robustesse en Production :

1. **Parité Train-Serve (Zéro *Training-Serving Skew*) : Feast** garantit une définition unique entre le *Point-in-Time* historique (S3) et le service RAM temps réel (Redis), empêchant toute fuite du futur

(*Data Leakage*).

2. **Déploiement Shadow / Canary (48 heures) :** Tout nouveau modèle reçoit d'abord 10% du trafic réel en miroir (*Shadow Mode*) sans bloquer les paiements clients. La bascule progressive (`10% → 50% → 100%`) ne s'effectue qu'après validation stricte des taux de faux positifs et de la latence p99.
3. **Surveillance Continue de la Dérive (Data & Concept Drift) : Evidently AI** calcule chaque jour le **PSI (*Population Stability Index*)** sur les distributions d'entrée et le taux de chargebacks retardés (*Concept Drift*). Si $\text{PSI} > 0.20$, une alerte PagerDuty déclenche automatiquement un réentraînement anticipé sous Airflow.