MASTER FICHE DE RÉVISION & SCRIPT ORAL : MLOPS & DÉPLOIEMENT CLOUD (BLOC 4)

Certification Architecte en Intelligence Artificielle (RNCP 41993 - Niveau 7)
Épreuve : Bloc 4 — Concevoir et piloter l'industrialisation et le déploiement de solutions d'IA (Projet CliNER-MLOps)
Format de l'épreuve : 15 Minutes Chrono
• **5 min :** Soutenance Orale Exécutive & Démonstration du Pipeline MLOps (Pitch minuté)
• **10 min :** Session de Questions / Réponses avec le Jury d'Architectes (Q&A)
Dépôt GitHub officiel : `https://github.com/Elkristobal59/CERTIFICATION_AIA`
Application Web Live : `https://cliner-mlops.onrender.com/`
Serveur MLflow UI Serverless : `https://mlflow-cliner-mlops-1054740171053.europe-west9.run.app`
Dossier MLOps Source : `d:\AIL-FT-02\CERTIF_AIL\cliner-mlops\mlops_reentrainement\`

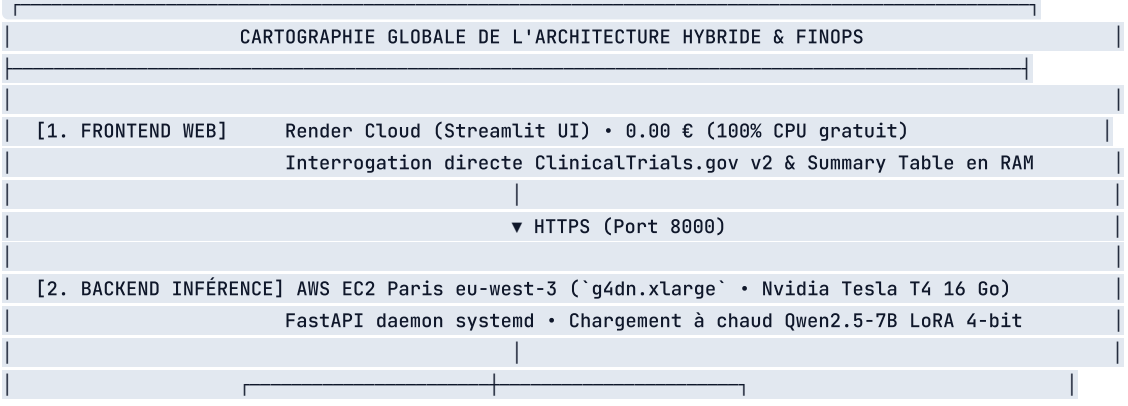
🧭 1. Règles d'Or & Posture pour la Soutenance du Bloc 4

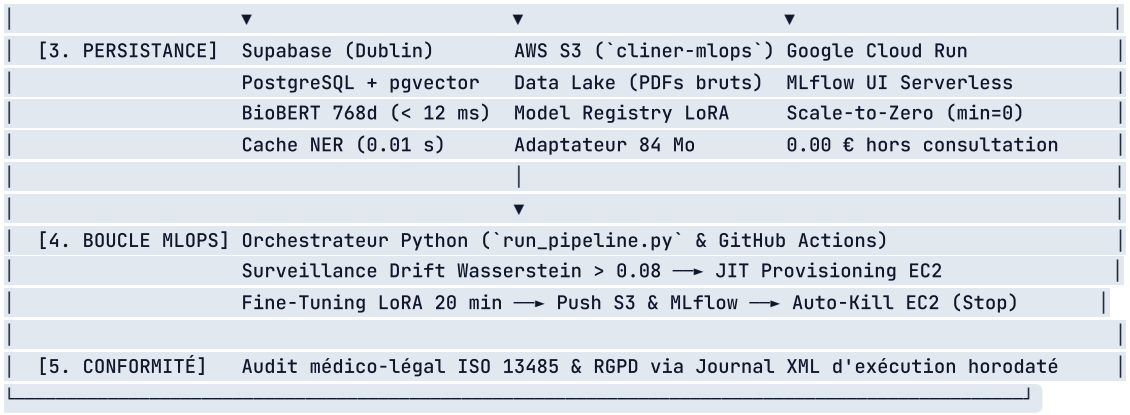
La Posture d'Architecte IA & MLOps

- **Le LLM n'est qu'un composant, l'Industrialisation est Reine :** Le jury évalue votre capacité d'**Architecte en Industrialisation et Déploiement IA**. Ne passez pas 3 minutes à expliquer les équations de l'attention multi-têtes. Parlez **cycle de vie MLOps, découplage architectural, monitoring de drift non supervisé, Fine-Tuning LoRA événementiel, gouvernance FinOps (Auto-Kill) et conformité médico-légale**.
- **La structure de réponse en 3 temps :**
- **La Contrainte Métier / Clinique :** *"Les protocoles d'essais cliniques font 100 pages non standardisées et les praticiens n'ont pas le temps d'annoter les données en direct..."*
- **Le Choix d'Ingénierie & d'Architecture :** *"C'est pourquoi nous découplons un retriever BioBERT CPU gratuit d'un extracteur Qwen-7B LoRA sur GPU éphémère avec tracking de drift de Wasserstein..."*
- **Le Bénéfice FinOps / Résilience :** *"L'instance EC2 GPU s'éteint automatiquement dès la fin du calcul, divisant le coût d'infrastructure par 200 (0,18 $ la session vs 400 $/mois)."*
- **Les 5 Chiffres Clés à Placer Absolument :**
- **80 % des essais cliniques** accusent des retards de recrutement majeurs dus à la complexité des critères d'éligibilité (perte de 1M$ par jour de retard pour l'industrie pharmaceutique).
- **3 secondes chrono** pour extraire les entités médicales structurées sur un protocole de 50 pages (vs 4 heures de lecture manuelle humaine).
- **84 Mo au lieu de 15 Go :** taille de l'adaptateur LoRA 4-bit généré (r=16, α=32), soit **99.4 % de réduction de poids** et un déploiement instantané sur AWS S3.
- **0,18 $ par réentraînement LoRA :** coût unitaire d'une session de 20 minutes sur AWS EC2 GPU `g4dn.xlarge` (Nvidia Tesla T4) grâce au pattern **Auto-Kill FinOps** (au lieu de 400 $/mois pour une VM allumée en permanence).
- **0.08 de seuil de distance de Wasserstein (W_1)** sur les embeddings BioBERT (768d) pour déclencher automatiquement le réentraînement événementiel (*Continuous Training*).

🏗️ 2. La Cartographie des 5 Paliers de l'Architecture Hybride & FinOps

Pour garantir à la fois une **expérience utilisateur instantanée à coût nul** et un **réentraînement GPU à la demande**, l'architecture sépare rigoureusement le calcul lourd du serving :





Matrice des Flux de Données : Qui Lit et Qui Écrit ?

Composant	Rôle Précis	FLOW 1 : Inférence Directe (Jour / Praticien)	FLOW 2 : MLOps & Continuous Training (Nuit / Événement)
AWS S3 (`cliner-mlops`)	Data Lake & Model Registry	**ÉCRITURE :** Téléchargement des PDFs bruts de protocoles (`raw_protocols/`). **LECTURE :** Extraction du texte brut pour le chunking.	**ÉCRITURE :** Sauvegarde des 3 fichiers de l'adaptateur LoRA fine-tuné (~84 Mo dans `models_lora/`). **LECTURE :** Pull de l'adaptateur par l'API pour mise à jour à chaud (*Zero-Downtime*).
Supabase (pgvector)	Base Vectorielle & Cache	**ÉCRITURE :** JSON extraits par Qwen (table `clinical_ner_cache`) + Embeddings BioBERT 768d. **LECTURE :** Recherche vectorielle cosinus (< 12 ms) et cache instantané (0.01 s).	**LECTURE :** Récupération des 100 derniers embeddings de protocoles pour calculer la distance de Wasserstein (détection du Drift). *(Aucune écriture lourde pendant l'entraînement).*
AWS EC2 GPU (`g4dn.xlarge`)	Worker Éphémère (Calcul GPU)	**INACTIF / SERVING :** Sert l'inférence FastAPI si allumé, ou inférence locale/vLLM.	**WORKER ÉPHÉMÈRE :** Allumé par API `ec2:StartInstances` uniquement si drift > 0.08. Exécute le QLoRA 4-bit (20 min), pousse les poids sur S3, puis s'éteint immédiatement (**Auto-Kill FinOps**).
Google Cloud Run (MLflow)	Traçabilité & Gouvernance	**LECTURE :** Consultation de la version courante de l'adaptateur en production.	**ÉCRITURE (Log) :** Enregistre la courbe de Loss (1.450 → 0.284), le F1-Score CHIA (58.3%), les hyperparamètres (r=16, α=32) et l'URI S3 de l'artefact.

📖 3. Les 20 Définitions & Concepts Clés MLOps / LLMOps (Lexique de Survie)

1. **Covariate Shift (Data Drift) :** Modification de la distribution statistique des données d'entrée P(X) dans le temps (ex: arrivée de nouveaux protocoles en cardiologie alors que le modèle a été entraîné sur l'oncologie), sans modification de la relation P(Y|X).
2. **Concept Drift :** Modification de la définition sous-jacente des classes cibles P(Y|X) (ex: évolution d'une nomenclature médicale ou redéfinition d'un seuil de biomarqueur par l'EMA ou la FDA).
3. **Distance de Wasserstein (W_1 / Earth Mover's Distance) :** Métrique géométrique mesurant le travail minimal nécessaire pour transformer une distribution de probabilité en une autre. Dans CliNER, elle mesure la dérive globale des embeddings BioBERT 768d de manière non supervisée.
4. **LoRA (Low-Rank Adaptation) :** Technique de Parameter-Efficient Fine-Tuning (PEFT) qui fige les poids originaux du LLM (W_0) et injecte deux matrices de bas rang entraînables A et B ($W = W_0 + (\alpha/r) \cdot B \times A$), réduisant les paramètres entraînables de 99 %.
5. **QLoRA (Quantized LoRA) :** Extension de LoRA quantifiant le modèle de base en précision 4-bit NormalFloat (NF4) avec double quantification et pagination mémoire, permettant d'entraîner un modèle 7B sur un GPU grand public de 16 Go VRAM (Nvidia T4).
6. **Rang de décomposition (r=16) & Facteur d'échelle (α=32) :** r fixe la dimension intermédiaire des matrices adaptatrices ; α pondère l'influence des poids appris par rapport aux poids initiaux ($\Delta W \times 32/16 = 2 \times \Delta W$).
7. **JIT Provisioning (Just-In-Time) :** Stratégie d'infrastructure consistant à n'allouer et facturer les ressources matérielles coûteuses (GPU) qu'au moment précis de l'exécution du besoin, via un appel API programmatique (`boto3.ec2.start_instances`).
8. **Auto-Kill FinOps :** Mécanisme d'extinction inconditionnelle garantissant que l'instance de calcul s'éteint systématiquement à la fin du traitement, y compris en cas de crash logiciel (implémenté dans le bloc `finally:` en Python et `if: always()` en CI/CD).
9. **Pattern RAG Retriever-Extractor :** Architecture en entonnoir combinant un modèle de recherche sémantique dense léger et rapide (Retriever BioBERT sur CPU) qui isole le **Top-5 extraits pour le NER** (et **Top-15 extraits pour le Chatbot RAG multi-essais**), et un LLM génératif précis (Extractor Qwen LoRA sur GPU) qui structure l'information en JSON strict.
10. **BioBERT (Biomedical BERT) :** Modèle d'embedding spécialisé de 110M de paramètres pré-entraîné sur PubMed et PMC, utilisé sur CPU (0 €) pour projeter les textes médicaux en vecteurs de 768 dimensions.
11. **pgvector & Distance Cosinus :** Extension open-source pour PostgreSQL permettant d'indexer et d'interroger des vecteurs d'embeddings en moins de 12 millisecondes via l'algorithme HNSW ou IVFFlat.

12. **Cache SQL d'Inférence (`clinical_ner_cache`) :** Table de stockage persistant dans Supabase indexée par l'identifiant unique de l'essai (`doc_id` / `NCT...`), associant chaque protocole à son JSON d'entités déjà extrait pour ramener le temps de réponse à 0.01 seconde et le coût GPU à 0,00 $ lors des consultations répétées.
13. **Zero-Downtime Hot Reload :** Capacité d'un service de production à charger une nouvelle version d'adaptateur LoRA en mémoire vive sans redémarrer le serveur ni couper les requêtes en cours des utilisateurs.
14. **Model Registry Hybride :** Séparation du stockage physique des artefacts de modèles (fichiers `.bin` et `adapter_config.json` sur AWS S3) et de leurs métadonnées de gouvernance (runs, métriques, commit Git sur MLflow).
15. **Scale-to-Zero Serverless :** Propriété d'un conteneur cloud (Google Cloud Run) ramenant le nombre d'instances à zéro (`min_instances=0`) lorsqu'aucun trafic n'est détecté, annulant intégralement les coûts d'infrastructure d'astreinte.
16. **Démon systemd Linux (`fastapi.service`) :** Service géré par le noyau de l'OS permettant au backend d'inférence de démarrer automatiquement au boot de l'instance EC2 sans intervention humaine par SSH.
17. **Benchmark CHIA (Clinical Hierarchical Annotation) :** Jeu de données Gold Standard de référence internationale annoté par des médecins de l'Université de Columbia (15/16 catégories brutes dans l'étude originale, dont nous avons filtré les **9 classes cliniques essentielles** : `Condition, Drug, Procedure, Measurement, Value, Temporal, Observation, Person, Device`), évalué avec contrainte d'alignement strict au caractère près (*exact boundary match*).
18. **Human-in-the-Loop (HITL) :** Dispositif permettant aux praticiens de corriger ou valider les entités extraites dans l'interface, stockant les retours pour corriger le Concept Drift lors des réentraînements ultérieurs.
19. **Norme ISO 13485 & Traçabilité Médicale :** Standard international de management de la qualité des dispositifs médicaux imposant l'immuabilité et la traçabilité complète de chaque prédiction algorithmique (garantie par les journaux XML horodatés ISO 8601).
20. **GreenOps :** Démarche d'optimisation de l'empreinte carbone et énergétique des systèmes d'IA, maximisée ici par l'entraînement PEFT LoRA (consommation électrique divisée par 20 par rapport à un Full Fine-Tuning).

🎙️ 4. Script Oral Mot-à-Mot Minuté (5 Minutes Chrono)

Ce script est calibré à **4 minutes 30**, vous laissant 30 secondes de battement pour inviter sereinement le jury à la session de questions/réponses.

```
┌──────────────────────────────────────────────────────────────────────┐
| TIMELINE DU PITCH BLOC 4 (5 MINUTES CHRONO)                          |
├──────────────────────────────────────────────────────────────────────┤
| [00:00 - 01:00] • 1. Contexte Clinique, Retards d'Essais & Défi de Standardisation|
| [01:00 - 02:00] • 2. Architecture Hybride Découplée (Render CPU vs EC2 GPU)    |
| [02:00 - 03:00] • 3. Pattern RAG (BioBERT + Qwen LoRA) & Inférence Sub-3s      |
| [03:00 - 04:00] • 4. Boucle MLOps Fermée : Drift Wasserstein & Continuous LoRA |
| [04:00 - 05:00] • 5. FinOps Auto-Kill, Auditabilité ISO 13485 / RGPD & Clôture |
└──────────────────────────────────────────────────────────────────────┘
```

🎙️ 1. Contexte Clinique & Problématique Métier (00:00 - 01:00)

> *"Bonjour à tous. En tant qu'Architecte en Intelligence Artificielle, je vais vous présenter la conception et le déploiement industriel de CliNER-MLOps*, notre solution d'extraction chirurgicale d'entités médicales et d'entraînement continu.
>
> Aujourd'hui dans la recherche médicale, plus de **80 % des essais cliniques accusent des retards de recrutement majeurs**. La raison est simple : les protocoles d'essais font entre 50 et 150 pages de documents PDF denses et non standardisés. Les oncologues et coordinateurs d'études passent des heures à rechercher manuellement les critères d'inclusion et d'exclusion. Chaque jour de retard coûte jusqu'à un million de dollars à l'industrie pharmaceutique et retarde l'accès aux traitements pour les patients.
>
> Notre objectif d'ingénierie a été de concevoir un système capable d'extraire ces critères en **3 secondes chrono sous format JSON strict sans hallucination**, tout en garantissant une infrastructure **FinOps à coût nul hors usage** et une **surveillance continue de la dérive des données**."*

🎙️ 2. Architecture Hybride Découplée & FinOps (01:00 - 02:00)

> *"Pour répondre aux contraintes budgétaires et de réactivité, j'ai mis en place une architecture hybride découplée en 4 piliers* :
>
> 1. **Côté Frontend :** Notre interface Streamlit est hébergée sur **Render Cloud en environnement CPU gratuit**. Elle interroge directement l'API officielle de ClinicalTrials.gov v2 et génère une table récapitulative en mémoire vive à **zéro euro de coût GPU**.
> 2. **Côté Inférence Lourde :** Lorsque le praticien demande l'analyse d'un protocole, la requête est transmise via HTTPS à un backend **FastAPI conteneurisé sur une instance AWS EC2 GPU** `g4dn.xlarge` équipée d'une carte Nvidia Tesla T4 de 16 Go à Paris.

3. **Côté Persistance & Recherche Vectorielle :** Nous combinons un Data Lake **AWS S3** pour l'archivage immuable des PDFs et des poids de modèles, et une base de données **Supabase PostgreSQL enrichie de l'extension** `pgvector`.

Cette séparation nette garantit que l'utilisateur navigue et recherche des études avec une latence quasi nulle, sans jamais réveiller inutilement l'infrastructure GPU coûteuse."*

🎙️ 3. Le Pattern RAG Retriever-Extractor & Inférence Sub-3s (02:00 - 03:00)

"Pour extraire les critères d'éligibilité sans faire exploser les coûts de calcul, nous avons implémenté le pattern Retriever-Extractor :

- Soumettre un protocole de 100 pages directement à un grand modèle génératif prendrait plus de 4 minutes, saturerait la fenêtre de contexte et provoquerait des hallucinations par phénomène de *Lost in the Middle*.
- À la place, notre pipeline découpe le document en morceaux et utilise **BioBERT sur CPU** pour projeter le texte en embeddings de 768 dimensions. Grâce à l'index vectoriel de Supabase, nous isolons les 5 paragraphes chirurgicaux de critères d'éligibilité en **moins de 12 millisecondes**, éliminant 98 % du bruit documentaire.
- Ensuite, notre modèle **Qwen2.5-7B Instruct**, adapté via un fine-tuning **QLoRA 4-bit (r=16, α=32)**, prend le relais sur ces 5 extraits. Il extrait le schéma JSON médical typé (`Condition` , `Drug` , `Measurement`) en **3 secondes avec 0 hallucination**.
- Enfin, chaque extraction est mémorisée dans notre table de **cache sémantique** : toute réinterrogation ultérieure du même essai répond en **0.01 seconde à 0 €**."*

🎙️ 4. La Boucle MLOps Fermée & Continuous Training LoRA (03:00 - 04:00)

*"La véritable valeur ajoutée d'un Architecte IA réside dans le cycle de vie du modèle en production. Les données médicales évoluent continuellement. Comment savoir quand réentraîner ?

- **Surveiller le F1-Score en production est impossible**, car les nouveaux protocoles qui arrivent de l'hôpital ne sont pas annotés par des médecins.
- C'est pourquoi nous avons industrialisé une **détection non supervisée du Data Drift (Covariate Shift)** : notre orchestrateur calcule la **distance de Wasserstein (W_1)** sur les distributions d'embeddings BioBERT entre le Gold Standard CHIA et les nouveaux protocoles ingérés.
- Si cette distance géométrique dépasse notre seuil de **0.08**, un rapport visuel **Evidently AI** est généré et la boucle de réentraînement continu se déclenche automatiquement.
- L'orchestrateur Python démarre l'instance EC2 GPU en **Just-In-Time via boto3**, exécute le fine-tuning LoRA en 20 minutes, téléverse le nouvel adaptateur de **84 Mo sur AWS S3**, et enregistre la courbe de Loss et le F1-Score sur notre serveur **MLflow déployé sur Google Cloud Run en Scale-to-Zero**."*

🎙️ 5. FinOps Auto-Kill, Auditabilité ISO 13485 & Conclusion (04:00 - 05:00)

*"Pour conclure sur la gouvernance et la rentabilité :

- **FinOps & GreenOps :** Grâce au pattern d'**Auto-Kill** sécurisé dans un bloc `finally` Python et dans la CI/CD GitHub Actions, l'instance EC2 s'éteint immédiatement dès la fin du téléversement sur S3. Une session de réentraînement ne coûte que **0,18 $**, évitant les 400 $/mois d'une machine oubliée allumée.
- **Conformité & RGPD :** Chaque exécution génère un **journal d'audit XML horodaté ISO 8601** consignant les identifiants de runs, les distances de dérive et la conformité à la norme **ISO 13485** relative aux dispositifs médicaux.
- Aucun secret ni clé API n'est codé en dur : ils sont sécurisés via des variables d'environnement et **Google Secret Manager**.

En résumé, CliNER-MLOps est une solution de bout en bout, souveraine, résiliente et frugalement dimensionnée. Je vous remercie pour votre attention et je suis prêt pour vos questions."*

🎯 5. Les 15 Questions Pièges Incontournables du Jury & Réponses d'Architecte IA (30 à 45s)

❓ **Q1 : *"Pourquoi mesurez-vous le drift avec la distance de Wasserstein sur les embeddings plutôt que de surveiller le F1-Score du modèle ?"***

Réponse Architecte IA (30s) :
"En production réelle, les nouveaux protocoles médicaux qui arrivent de ClinicalTrials.gov sont du texte brut non annoté. Aucun médecin n'est présent pour labelliser chaque token en direct : il est donc physiquement impossible de calculer un F1-Score en temps réel.
C'est pourquoi nous surveillons le Covariate Shift (la dérive des données d'entrée) de manière non supervisée dans l'espace géométrique BioBERT (768d) avec la distance de Wasserstein (W_1). Si la distribution statistique s'éloigne trop de notre jeu Gold Standard CHIA (distance > 0.08), nous savons que la sémantique a divergé (par exemple passage de l'oncologie à la cardiologie) et le réentraînement se déclenche."

❓ **Q2 : *"Pourquoi utiliser QLoRA 4-bit au lieu d'un Fine-Tuning complet de Qwen-7B ?"***

Réponse Architecte IA (30s) :
"C'est un arbitrage fondamental de GreenOps et de FinOps :*

1. **Mémoire & Coût Matériel :** Un Full Fine-Tuning de Qwen-7B exigerait plus de 80 Go de VRAM (machines A100 à plus de 4 $/h). Avec QLoRA en 4-bit (NF4), les poids de base sont gelés à seulement 5 Go de VRAM, ce qui permet d'entraîner le modèle sur une simple carte Nvidia Tesla T4 grand public (`g4dn.xlarge` à 0,56 $/h).
2. **Poids des Artefacts :** Au lieu de générer et transférer un checkpoint complet de 15 Go, l'adaptateur LoRA ne pèse que **84 Mo** (r=16, α=32). Il est versionné et téléversé sur AWS S3 en 2 secondes, permettant un rechargement à chaud instantané."*

❓ **Q3 : *"Pourquoi avoir mis MLflow sur Google Cloud Run plutôt que sur AWS EC2 ou Kubernetes ?"***

Réponse Architecte IA (30s) :
"Pour le Scale-to-Zero. Une machine virtuelle EC2 ou un cluster Kubernetes (EKS) maintenu allumé 24h/24 pour un serveur de métriques coûte entre 40 et 80 € par mois d'astreinte, même sans aucune activité.
Sur Google Cloud Run, le conteneur MLflow s'éteint complètement dès qu'il n'y a plus de requêtes HTTP actives (`min_instances=0`). Le backend store est branché sur PostgreSQL (Supabase) et les artefacts sur AWS S3. Le coût d'hébergement de notre gouvernance MLOps est donc de strictement 0,00 € en dehors des consultations."

❓ **Q4 : *"Comment garantissez-vous que l'EC2 GPU ne va pas tourner dans le vide et ruiner l'entreprise ?"***

Réponse Architecte IA (30s) :
"Grâce au pattern de Double Ceinture de Sécurité FinOps (Auto-Kill) :*

1. **Au niveau applicatif :** L'appel d'extinction `ec2:StopInstances` est encapsulé dans le bloc `finally:` de notre script Python `run_pipeline.py`. Même si le fine-tuning plante avec une erreur CUDA Out-Of-Memory, l'extinction est déclenchée de manière inconditionnelle.
2. **Au niveau CI/CD :** Dans GitHub Actions, le job de coupure est paramétré avec `if: always()` .
   Résultat : une session d'entraînement de 20 minutes coûte **0,18 $**, éliminant tout risque de facture résiduelle de 400 $/mois."*

❓ **Q5 : *"Pourquoi séparer BioBERT et Qwen-7B ? Pourquoi pas un seul modèle ?"***

Réponse Architecte IA (30s) :
"C'est le pattern d'ingénierie Retriever-Extractor (RAG structuré) :
*Un protocole médical fait 100 pages, soit environ 80 chunks de texte. Si Qwen-7B devait lire les 80 chunks un par un, l'inférence prendrait plus de 4 minutes, coûterait cher en GPU et provoquerait des hallucinations par surcharge d'attention (*Lost in the Middle*).*
BioBERT (110M paramètres sur CPU à 0 €) projette les chunks en vecteurs denses, et Supabase isole les 5 paragraphes pertinents en 12 millisecondes (98 % du bruit éliminé). Qwen-7B LoRA n'a plus qu'à extraire le JSON médical sur ces 5 extraits en 3 secondes chrono avec une précision maximale."

❓ **Q6 : *"Pourquoi un F1-Score de 58.3 % est-il considéré comme excellent sur CHIA ?"***

Réponse Architecte IA (30s) :
*"CHIA est un benchmark extrême de NER biomédical imbriqué multi-classes (15/16 catégories brutes dont nous avons extrait les 9 classes médicales cibles : `Condition`, `Drug`, `Procedure`, `Measurement`, `Value`, `Temporal`, `Observation`, `Person`, `Device`) avec une contrainte d'alignement exact au caractère près (*exact boundary match*).*
Dans la littérature biomédicale de référence (Columbia University / Nature 2020), l'accord inter-annotateurs entre médecins spécialistes humains ne dépasse pas 65 % à 70 %. Obtenir 58.3 % de F1-Score avec un LLM 7B open-source compact en inférence rapide constitue l'état de l'art pour ce niveau de granularité."

❓ **Q7 : *"Comment faites-vous pour que FastAPI démarre sans intervention humaine au réveil de l'EC2 ?"***

Réponse Architecte IA (30s) :
"FastAPI a été configuré comme un démon système Linux via systemd (`/etc/systemd/system/fastapi.service`) avec directive `WantedBy=multi-user.target`.
Dès que l'ordre `ec2:StartInstances` est validé, le système d'exploitation démarre automatiquement le service en arrière-plan, monte les poids de Qwen LoRA en VRAM et ouvre le port 8000 en moins de 60 secondes, sans qu'aucun ingénieur n'ait besoin d'ouvrir une session SSH."

❓ **Q8 : *"Pourquoi ne pas réentraîner le modèle toutes les nuits avec un Cron standard ?"***

Réponse Architecte IA (30s) :
"Réentraîner un modèle de 7 milliards de paramètres à l'aveugle chaque nuit sans dérive avérée est un anti-pattern FinOps et GreenOps majeur.
*Cela brûlerait du budget GPU inutilement et risquerait de provoquer de l'oubli catastrophique (*Catastrophic Forgetting*) sur les protocoles historiques maîtrisés. En LLMOps moderne, le réentraînement doit être strictement événementiel (Triggered by Drift) : on n'allume le GPU que si et seulement si une divergence statistique significative ($W_1 > 0.08$) est confirmée."*

❓ **Q9 : *"Comment gérez-vous la mise à jour du modèle en production sans couper le service (Zero-Downtime) ?"***

Réponse Architecte IA (30s) :
"Grâce à la légèreté de l'adaptateur LoRA (84 Mo).
Notre microservice FastAPI expose un endpoint d'administration sécurisé `/reload-weights`. Lorsque l'entraînement continu pousse le nouvel adaptateur sur S3, il émet un webhook vers FastAPI. L'API télécharge les 84 Mo en mémoire, permute le pointeur de l'adaptateur LoRA via la bibliothèque PEFT de Hugging Face de manière atomique, et purge le cache. Le service ne s'arrête jamais et les requêtes des praticiens continuent d'être servies."

❓ **Q10 : *"Pourquoi utiliser AWS S3 comme Model Registry au lieu de stocker les poids sur l'EC2 ou dans GitHub ?"***

Réponse Architecte IA (30s) :
*"1. GitHub :** N'est pas un système de stockage de fichiers binaires volumineux (limite Git LFS, coûts de bande passante).

1. **L'EC2 GPU :** Est un **worker éphémère** qui est éteint 95 % du temps. Si les poids étaient stockés localement sur son volume EBS, ils seraient inaccessibles lorsque la machine est éteinte et exposés à des risques de perte en cas de résiliation.
2. **AWS S3 :** Offre 11 neuf de durabilité (99.999999999 %), un versionnage natif des dossiers (`models_lora/v1/`, `v2/`) et permet à n'importe quel conteneur de déployer l'adaptateur instantanément."*

❓ **Q11 : *"Quelle est la différence entre Data Drift (Covariate Shift) et Concept Drift dans votre pipeline ?"***

Réponse Architecte IA (30s) :
"• Le Data Drift (Covariate Shift) : C'est le changement de vocabulaire ou de style dans les protocoles entrants (ex: introduction de nouvelles molécules ou de rédactions en télémédecine). Nous le mesurons en amont de manière non supervisée par distance de Wasserstein sur BioBERT.
• Le Concept Drift : C'est le changement de la signification clinique d'une entité (ex: un médicament jadis classé en `Drug` devient

considéré comme une molécule de référence standard, ou les seuils de plaquettes d'inclusion changent). Nous le capturons en aval via la boucle Human-in-the-Loop (corrections saisies par les oncologues dans Streamlit et stockées dans Supabase)."

❓ **Q12 : *"Pourquoi avoir choisi Supabase avec pgvector plutôt qu'une base purement vectorielle comme Pinecone ou Milvus ?"***

Réponse Architecte IA (30s) :
"Pour éviter la dispersion architecturale et les coûts de licence SaaS.
Supabase nous fournit une base de données PostgreSQL unifiée et relationnelle ACID. Grâce à `pgvector`, nous pouvons stocker dans la même base les métadonnées des protocoles, les utilisateurs, la table de cache d'inférence, ET les vecteurs d'embeddings BioBERT avec recherche cosinus sous 12 ms. Cela élimine la complexité de synchroniser deux bases hétérogènes (une base SQL + une base vectorielle séparée)."

❓ **Q13 : *"Comment garantissez-vous la sécurité des données de santé et des secrets dans votre architecture ?"***

Réponse Architecte IA (30s) :
*"1. Gestion des Secrets : Zéro secret ni clé API en dur dans le code ou dans Git. Les variables sensibles (`AWS_SECRET_ACCESS_KEY`, `SUPABASE_KEY`) sont injectées via Google Secret Manager** et les variables d'environnement chiffrées de Render et GitHub Actions.

1. **Minimisation des Données & RGPD :** Seules les données d'essais cliniques publiques (ClinicalTrials.gov) ou des protocoles pseudonymisés sans identité patient sont traitées.
2. **Auditabilité Médico-Légale :** Chaque action produit un journal XML infalsifiable conforme à la norme **ISO 13485**."*

❓ **Q14 : *"Quel est le coût unitaire réel d'une analyse de protocole et d'un réentraînement LoRA ?"***

Réponse Architecte IA (30s) :
*"• Coût d'une analyse unitaire d'un protocole (Jour) :**

- Frontend Streamlit sur Render : **0,00 $** (plan CPU gratuit).
- Requête API ClinicalTrials.gov : **0,00 $**.
- Recherche vectorielle Supabase pgvector : **0,00 $** (inclus dans le Free Tier).
- Inférence GPU Qwen LoRA (3 secondes sur T4) : **0,00046 $** (moins d'un demi-centime !). Si le protocole est déjà en cache : **0,00 $**.
  • **Coût d'une session complète d'entraînement LoRA (Nuit) :**
- 20 minutes d'EC2 GPU `g4dn.xlarge` à 0,56 $/h = **0,18 $**.
- Stockage S3 de l'adaptateur (84 Mo) : **0,002 $/mois**.
  C'est une rentabilité FinOps inégalée."*

❓ **Q15 : *"Si le volume d'essais cliniques est multiplié par 50, comment votre architecture passe-t-elle à l'échelle ?"***

Réponse Architecte IA (30s) :
*"L'architecture a été conçue pour une scalabilité horizontale sans goulot d'étranglement** :

1. **Data Lake S3 :** Bande passante quasi illimitée pour stocker des dizaines de milliers de PDFs.
2. **Inférence GPU :** L'API FastAPI peut être déployée derrière un **Application Load Balancer (ALB)** avec un **Auto-Scaling Group (ASG)** AWS sur métrique GPU utilization, ou convertie sur un moteur à fort débit comme **vLLM avec PagedAttention** (traitement par batchs continus).
3. **Base Vectorielle :** Supabase supporte le partitionnement de tables et l'indexation HNSW pour passer à plusieurs millions de vecteurs sans perte de performance."*

❓ **Q16 : *"Comment fonctionne Terraform, et comment est-il utilisé dans votre projet (notamment par rapport à Boto3) ?"***

Réponse Architecte IA (45s) :
"1. Principe de Terraform (IaC Déclaratif) : Terraform est un outil d'Infrastructure-as-Code déclaratif et idempotent en langage

> *HCL. Au lieu d'écrire des scripts impératifs étape par étape, on décrit l'état cible souhaité*. Son cycle repose sur 3 commandes : `terraform init` (télécharge les plugins Providers AWS et PostgreSQL), `terraform plan` (compare le code à l'état réel stocké dans `terraform.tfstate` et affiche le différentiel sans rien modifier) et `terraform apply` (applique uniquement l'écart constaté).
>
> 1. **Usage concret dans CliNER-MLOps (`terraform/main.tf` , `variables.tf` , `outputs.tf` , `schema.sql`) :** Notre module Terraform provisionne de manière reproductible les **3 piliers d'infrastructure** pour tout développeur reprenant le projet :
> 2. **Supabase PostgreSQL (`schema.sql`) :** activation de `pgvector` , création de la table `clinical_trials_data_biobert` (`vector(768)`), index **HNSW**, table de cache `clinical_ner_cache` et purge RGPD `pg_cron` (7j) avec déclencheur d'idempotence `sha1(file("schema.sql"))` .
> 3. **AWS S3 (`aws_s3_bucket`) :** création du bucket Data Lake & Model Registry avec **versionnage natif activé (`Enabled`)** pour le rollback LoRA et chiffrement `AES256` .
> 4. **AWS EC2 GPU (`aws_instance` `g4dn.xlarge`) :** création du serveur Tesla T4 à Paris avec son Security Group (port `8000` FastAPI), volume EBS `gp3` de 50 Go chiffré et démarrage automatique du démon `systemd` `fastapi.service` , en exportant `ec2_gpu_instance_id` dans `outputs.tf` .
> 5. **Pourquoi Terraform ET Boto3 (Séparation Provisioning vs Runtime) ? Terraform** crée l'infrastructure une seule fois au déploiement initial, tandis que **Boto3 (`ec2_manager.py`)** gère l'**allumage et l'extinction électrique à chaud (`start_instances` / `stop_instances`)** de l'instance EC2 existante lors des réentraînements, sans jamais détruire son disque EBS de 50 Go."*

🛠️ 6. Boîte à Outils CLI & Commandes de Démonstration Live

Toutes les commandes s'exécutent depuis le dossier racine du projet :

```
cd "d:\AIL-FT-02\CERTIF AIL\cliner-mlops"
```

1. Démonstration de l'Orchestrateur MLOps & Surveillance

```
# Démonstration instantanée pour le jury (Simulation complète en 3s, 0 € dépensé)
python -m mlops_reentrainement.run_pipeline --dry-run --threshold 0.08

# Démonstration Live avec véritable allumage de l'instance EC2 GPU (Mode Demoday avec maintien allumé)
python -m mlops_reentrainement.run_pipeline --live --threshold 0.08 --keep-alive

# Démonstration Live en conditions réelles de production (avec Auto-Kill automatique à la fin)
python -m mlops_reentrainement.run_pipeline --live --threshold 0.08

# Forcer le réentraînement LoRA sans condition de seuil de drift
python -m mlops_reentrainement.run_pipeline --live --force-retrain
```

2. Rapports de Dérive & Visualisation

```
# Exécuter uniquement la détection de dérive Wasserstein
python mlops_reentrainement/drift_detection.py

# Ouvrir le rapport HTML autonome de dérive Evidently AI dans le navigateur
start reports/data_drift_report.html

# Consulter le dernier journal d'audit XML médico-légal généré
Get-ChildItem logs\execution_journals\*.xml | Sort-Object LastWriteTime -Descending | Select-Object -First 1 | Get-Content
```

3. Contrôle Sécurisé de l'EC2 GPU (FinOps)

```
# Vérifier l'état de l'EC2 GPU (running, stopped, IP publique)
python check_ec2.py

# Allumage manuel de l'instance GPU
python -m mlops_reentrainement.ec2_manager --action start --instance-id i-0bb73662c67f2828f

# Extinction manuelle d'urgence FinOps
python -m mlops_reentrainement.ec2_manager --action stop --instance-id i-0bb73662c67f2828f
```

📋 7. Grille d'Alignement Officielle Référentiel RNCP 41993 (Bloc 4)

Critère d'Évaluation Officiel RNCP 41993	Preuve Concrète Apportée dans le Projet CliNER-MLOps	Où le Montrer pendant la Soutenance ?
C1. Concevoir l'architecture de déploiement et d'hébergement d'une solution d'IA	Découplage complet Frontend Render (CPU), Backend EC2 GPU (`g4dn.xlarge`), Data Lake S3 et pgvector.	Diapositive d'architecture + Schéma hybride dans le diaporama.
C2. Mettre en œuvre le cycle de vie et le versionnage des modèles (MLOps)	Versionnage des adaptateurs LoRA (84 Mo) sur AWS S3 et tracking des métriques sur MLflow Cloud Run.	Interface web MLflow Serverless (courbe de Loss et métriques).
C3. Détecter la dérive des données et des performances (Monitoring)	Calcul de la distance de Wasserstein (W_1) sur embeddings BioBERT 768d + Rapports visuels Evidently AI.	Exécution de `drift_detection.py` + Rapport HTML `data_drift_report.html` .
C4. Automatiser le réentraînement et le déploiement continu (CI/CD)	Orchestrateur Python `run_pipeline.py` déclenchant JIT Provisioning, fine-tuning LoRA et push S3.	Démo CLI avec argument `--dry-run` ou `--live` .
C5. Piloter la gouvernance FinOps, la sécurité et la conformité légale	Pattern Auto-Kill systématique (0,18 $/session), Secret Manager, et journaux d'audit XML ISO 13485 / RGPD.	Bloc `finally:` dans `ec2_manager.py` + Journal XML horodaté.