CERTIFICATION · ARCHITECTE EN INTELLIGENCE ARTIFICIELLE (RNCP 41993 — BLOC 4)

🫀 CliNER-MLOps

Industrialisation, Déploiement Cloud Hybride, Continuous Training LoRA & FinOps



Christopher GILLERON · Soutenance Individuelle (5 min Pitch + 10 min Q&A)

1. Enjeu Clinique, Dataset CHIA & Prétraitement RAG

⏱️ Pitch 00:15 – 01:10 | Data & RAG

❌ Problématique Clinique & Données Brutes

- **450 000+ Essais Non Standardisés :** Protocoles PDF/JSON denses de 50 à 150 pages.
- **Goulot d'Étranglement :** 45 min de lecture / essai ; 80 %* des essais en retard de recrutement.
- **Échec des LLMs Bruts :** Hallucinations (Lost in the Middle), latence > 4 min et coût VRAM massif.
- **Défi MLOps en Production :** Nouveaux protocoles non annotés → filtrage RAG & drift non supervisé.

✅ Dataset CHIA & Prétraitement RAG

- **Benchmark CHIA (Nature 2020) :** 1 000 études, 12 409 critères et 41 000+ entités annotées.
- **Prétraitement Sans Fuite :** BRAT → ChatML (800 Train / 200 Test hermétiques, 0 synthétique).
- **Ingestion Duale & Data Lake S3 :** API ClinicalTrials.gov v2 (0 €) + PDF PyMuPDF archivés sur AWS S3.
- **Filtrage RAG BioBERT + pgvector :** Chunks (1000 car.) → Vecteurs 768d (12 ms) → Top-5 chunks (-98 % bruit).

** Sources : Tufts CSDD (Center for the Study of Drug Development / Pr. K. Getz) & Sully et al. (Trials Journal, BMC/NIH) : 80% à 86% des essais cliniques mondiaux subissent des retards critiques de recrutement.*

2. Entraînement QLoRA 4-bit, Métriques CHIA & Serving

⏱️ Pitch 01:10 – 02:05 | Modèle & API

🧠 Fine-Tuning QLoRA 4-bit (Qwen2.5-7B)

• **Choix Qwen2.5-7B + QLoRA (NF4) :** Backbone figé en 5 Go VRAM sur Nvidia T4 (0,56 $/h vs > 80 Go).

• **Hyperparamètres Optimisés :** Rang r=16, α=32, dropout=0.05, lr=2e-4 sur l'attention (q, k, v, o).

• **Adaptateur Ultra-Léger (84 Mo vs 15 Go) :** -99,4 % de poids, versionné en 2s sur AWS S3 (models_lora/vN/).

• **Zéro Hallucination par Design :** Extraction sur les 5 chunks RAG avec schéma JSON strict (15 classes).

⚡ Métriques CHIA & Inférence Temps Réel

• **Convergence Rapide (20 min) :** Chute régulière de la Loss de 1.450 → 0.284 tracée dans MLflow.

• **F1-Score Strict : 58,3 % (Précision : 63,0 %) :** Exact Boundary Match au caractère près (accord humain : 65–70 %).

• **Inférence GPU vLLM (< 3 secondes) :** PagedAttention (75 tok/s) + chargement LoRA à chaud (LoRARequest).

• **Cache Sémantique SHA-256 (0,01 s / 0 €) :** Table clinical_ner_cache (Supabase) évitant tout recalcul GPU.

3. Architecture Cloud Hybride, Docker & CI/CD

⏱ Pitch 02:05 – 03:10 | Infra & CI/CD

🖥 FRONT-END (STREAMLIT — RENDER 0 €)

- **Onglet 1 :** Recherche API v2 & Import PDF
- **Onglet 2 :** Summary Table & Export CSV / S3
- **Onglet 3 :** Entités Cliniques NER (Badges & JSON)
- **Onglet 4 :** Chatbot Médical Conversationnel RAG

⇄ PDF / Cache 0,01s

🗄 DATA LAKE & CACHE (TERRAFORM + AWS S3 + SUPABASE)

- **IaC Terraform :** Provisioning SSL pgvector & HNSW (< 30s)
- **AWS S3 Data Lake :** PDF bruts, CHIA & Registry LoRA (v1, v2… 84 Mo)
- **Cache NER (Supabase) :** Hash SHA-256 ➔ Réponse en 0,01 s (0 €)
- **Base Vectorielle :** Index HNSW 768d (12 ms) + Purge RGPD 7j

⬆ Pull / Push LoRA S3 (84 Mo)

⬇ Top-5 Vecteurs HNSW (12 ms)

⇄ API REST / JSON

⚡ BACKEND GPU & MLOPS (FASTAPI / vLLM / AWS EC2 T4)

1. **Filtrage RAG :** Chunks (1000 c.) + BioBERT Top-5 (-98 % bruit)
2. **Moteur vLLM [GPU T4] :** Qwen2.5-7B QLoRA 4-bit en 3 s + RAG
3. **Drift Monitoring :** Distance Wasserstein (Seuil $W_1 > 0.08$)
4. **Boucle Auto-Kill :** Réveil EC2 Boto3 ➔ LoRA 20 min ➔ Stop (0,18 $)

🛡 CI/CD, OBSERVABILITÉ & AUDIT RGPD

- **CI/CD GitHub :** flake8 + 11 tests PyTest + Docker
- **MLflow Cloud Run :** Serverless Scale-to-Zero (0 €)
- **Auditabilité :** Journaux XML ISO 13485 & RGPD

⇄ CI/CD & Traces

4. Drift Wasserstein, Continuous Training, Rollback & FinOps

🎯 Pitch 03:10 – 04:20 | Drift & FinOps

📈 Monitoring du Drift (W_1) & Rollback S3

• **Drift Non Supervisé (Wasserstein W_1) :** Calculé sur les embeddings BioBERT 768d (protocoles non annotés).

• **Seuil W_1 = 0.08 & Alerting Evidently AI :** $W_1 \leq 0.08$ → Stable (0 €) | $W_1 > 0.08$ → Rapport HTML + Réentraînement.

• **Versionnage S3 & Rollback Zero-Downtime :** Adaptateurs v1, v2… sur S3 ; bascule vers vN-1 si le F1 CHIA régresse.

💰 Orchestration EC2 JIT & Auto-Kill FinOps

• **Zéro Serveur GPU au Repos (0,00 €/h) :** L'instance AWS EC2 g4dn.xlarge (Tesla T4) est éteinte par défaut.

• **Provisioning JIT Boto3 (Si $W_1 > 0.08$) :** Réveil EC2 en 45s → QLoRA 4-bit (20 min) → Push S3 (84 Mo) & MLflow.

• **Double Ceinture Auto-Kill (finally: + CI/CD) :** Extinction forcée StopInstances → 0,18 $ / session (-99,9 % vs 400 $/mois).

🔒 Auditabilité Médico-Légale ISO 13485, Sécurité & Conformité RGPD

· Journaux d'audit XML horodatés ISO 8601 (/logs/xml) | · Zéro secret en dur (Google Secret Manager & GitHub Secrets)

· **Boucle MLOps 100 % automatisée : Détection Drift ($W_1 > 0.08$) ➔ Réveil EC2 ➔ QLoRA 4-bit ➔ Registry S3/MLflow ➔ Auto-Kill**

5. Démonstration Bout-en-Bout, API (/docs) & Bilan

⏱️ Pitch 04:20 – 05:00 | Démo & API

🖥️ Parcours Praticien & Validation MLOps

- **1. Recherche Live & Summary Table (0 €) :** Requête ClinicalTrials.gov v2 et tri instantané sur Render CPU.
- **2. Extraction NER JSON (3 s / Cache 0,01 s) :** Inférence Qwen-7B LoRA (Condition, Drug, Dose…) + Chatbot RAG.
- **3. API REST Documentée (Swagger /docs) :** Endpoints Pydantic : /process_text, /process_pdf, /chat_rag, /logs/xml.
- **4. Démo Orchestrateur MLOps :** run_pipeline.py --threshold 0.08 → Drift 0.0949 → Evidently → MLflow → Stop EC2.



✅ Synthèse des Métriques & Liens de Production

- **Modèle QLoRA :** F1 CHIA 58,3 % | Latence 3 s (0,01 s) | 84 Mo
- **Pipeline MLOps :** Drift W_1 > 0.08 | 11 tests PyTest | Coût 0,18 $
- **App & MLflow :** cliner-mlops.onrender.com | Cloud Run (0 €)
- **Dépôt GitHub :** github.com/Elkristobal59/CERTIFICATION_AIA