CHRISTOPHER GILLERON BLOC 4 FINAL PROJECT AI ARCHITECT – 17 NOVEMBRE 2026

Industrialisation, Déploiement Cloud Hybride, Continuous Training LoRA & FinOps



1. Enjeu Clinique, Dataset CHIA & Prétraitement RAG

❌ Problématique Clinique & Données Brutes

· **450 000+ Essais Non Standardisés :** Protocoles PDF/JSON denses de 50 à 150 pages.

· **Goulot d'Étranglement :** 45 min de lecture / essai ; 80 %* des essais en retard de recrutement.

· **Échec des LLMs Bruts :** Hallucinations (Lost in the Middle), latence > 4 min et coût VRAM massif.

· **Défi MLOps en Production :** Nouveaux protocoles non annotés → filtrage RAG & drift non supervisé.

✅ Dataset CHIA & Prétraitement RAG

· **Benchmark CHIA (Nature 2020) :** 1 000 études, 12 409 critères et 41 000+ entités annotées.

· **Prétraitement Sans Fuite :** BRAT → ChatML (800 Train / 200 Test hermétiques, 0 synthétique).

· **Ingestion Duale & Data Lake S3 :** API ClinicalTrials.gov v2 (0 €) + PDF PyMuPDF archivés sur AWS S3.

· **Filtrage RAG BioBERT + pgvector :** Chunks (1000 car.) → Vecteurs 768d (12 ms) → Top-5 chunks (-98 % bruit).

** Sources : Tufts CSDD (Center for the Study of Drug Development / Pr. K. Getz) & Sully et al. (Trials Journal, BMC/NIH) : 80% à 86% des essais cliniques mondiaux subissent des retards critiques de recrutement.*

2. Entraînement QLoRA 4-bit, Métriques CHIA & Serving

🧠 Fine-Tuning QLoRA 4-bit (Qwen2.5-7B)

· **Choix Qwen2.5-7B + QLoRA (NF4) :** Backbone figé en 5 Go VRAM sur Nvidia T4 (0,56 $/h vs > 80 Go).

· **Hyperparamètres Optimisés :** Rang r=16, α=32, dropout=0.05, lr=2e-4 sur l'attention (q, k, v, o).

· **Adaptateur Ultra-Léger (84 Mo vs 15 Go) :** - 99,4 % de poids, versionné en 2s sur AWS S3 (models_lora/vN/).

· **Zéro Hallucination par Design :** Extraction sur les 5 chunks RAG avec schéma JSON strict (9 classes).

⚡ Métriques CHIA & Inférence Temps Réel

· **Convergence Rapide (20 min) :** Chute régulière de la Loss de 1.450 → 0.284 tracée dans MLflow.

· **F1-Score Strict : 58,3 % (Précision : 63,0 %) :** Exact Boundary Match au caractère près (accord humain : 65–70 %).

· **Inférence GPU vLLM (< 3 secondes) :** PagedAttention (75 tok/s) + chargement LoRA à chaud (LoRARequest).

· **Cache SQL Clé NCT (0,01 s / 0 €) :** Table clinical_ner_cache (Supabase) évitant tout recalcul GPU.

3. Architecture Cloud Hybride, Docker & CI/CD

🖥️ FRONT-END (STREAMLIT — RENDER 0 €)

- **Onglet 1 :** Critères de sélection (API ClinicalTrials v2)
- **Onglet 2 :** Summary table, Export CSV/S3 & Inférence GPU
- **Onglet 3 :** Visualisation + filtre (Tableau NER & CSV)
- **Onglet 4 :** Chatbot RAG Médical Conversationnel

🛡️ CI/CD, OBSERVABILITÉ & AUDIT RGPD

- **CI/CD GitHub :** flake8 + 11 tests PyTest + Docker
- **MLflow (Google Cloud Run) :** Scale-to-Zero (0 €)
- **Auditabilité :** Journaux XML ISO 13485 & RGPD

⇄ PDF / Cache 0,01s

⇄ API REST / JSON

⇄ CI/CD & Traces

🗄️ DATA LAKE & CACHE (TERRAFORM + AWS S3 + SUPABASE)

- **IaC Terraform :** Provisioning SSL pgvector & HNSW (< 30s)
- **AWS S3 Data Lake :** PDF bruts, CHIA & Registry LoRA (v1, v2… 84 Mo)
- **Cache NER (Supabase) :** Clé doc_id (NCT) ➔ Réponse en 0,01 s (0 €)
- **Base Vectorielle :** Index HNSW 768d (12 ms) + Purge RGPD 7j

↑ Pull / Push LoRA S3 (84 Mo)

↓ Top-5 / Top-15 HNSW (12 ms)

⚡ BACKEND GPU & MLOPS (FASTAPI / vLLM / AWS EC2 T4)

1. **Filtrage BioBERT :** Chunks (1000 c.) ➔ Top-5 (NER) / Top-15 (RAG)
2. **Moteur vLLM :** Qwen2.5-7B QLoRA 4-bit (NER 3 s) & Chatbot RAG
3. **Drift Monitoring :** Distance Wasserstein (Seuil $W_1 > 0.08$)
4. **Boucle Auto-Kill :** Réveil EC2 Boto3 ➔ LoRA 20 min ➔ Stop

4. Drift Wasserstein, Continuous Training, Rollback & FinOps

📈 Monitoring du Drift (W_1) & Rollback S3

· **Drift Non Supervisé (Wasserstein W_1) :** Calculé sur les embeddings BioBERT 768d (protocoles non annotés).

· **Seuil $W_1 = 0.08$ & Alerting Evidently AI :** $W_1 \leq 0.08$ → Stable (0 €) | $W_1 > 0.08$ → Rapport HTML + Réentraînement.

· **Versionnage S3 & Rollback Zero-Downtime :** Adaptateurs v1, v2… sur S3 ; bascule vers vN-1 si le F1 CHIA régresse.

💰 Orchestration EC2 JIT & Auto-Kill FinOps

· **Zéro Serveur GPU au Repos (0,00 €/h) :** L'instance AWS EC2 g4dn.xlarge (Tesla T4) est éteinte par défaut.

· **Provisioning JIT Boto3 (Si $W_1 > 0.08$) :** Réveil EC2 en 45s → QLoRA 4-bit (20 min) → Push S3 (84 Mo) & MLflow.

· **Double Ceinture Auto-Kill (finally: + CI/CD) :** Extinction forcée StopInstances → 0,18 $ / session (-99,9 % vs 400 $/mois).

🔒 Auditabilité Médico-Légale ISO 13485, Sécurité & Conformité RGPD

· Journaux d'audit XML horodatés ISO 8601 (/logs/xml) | · Zéro secret en dur (Google Secret Manager & GitHub Secrets)

· Boucle MLOps 100 % automatisée : Détection Drift ($W_1 > 0.08$) ➔ Réveil EC2 ➔ QLoRA 4-bit ➔ Registry S3/MLflow ➔ Auto-Kill

5. Démonstration Bout-en-Bout, API (/docs) & Bilan

🖥️ Parcours Praticien & Validation MLOps

· **1. Recherche Live & Summary Table (0 €) :** Requête ClinicalTrials.gov v2 et tri instantané sur Render CPU.

· **2. Extraction NER JSON (3 s / Cache 0,01 s) :** Inférence Qwen-7B LoRA (Condition, Drug…) + Chatbot RAG.

· **3. API REST Documentée (Swagger /docs) :** Routes FastAPI : /process_text, /process_pdf, /chat_rag, /monitoring/drift-report, /logs/xml.

· **4. Démo Orchestrateur MLOps :** run_pipeline.py --threshold 0.08 → Drift 0.0949 → Evidently → MLflow → Stop EC2.



✅ Synthèse des Métriques & Liens de Production

· **Modèle QLoRA :** F1 CHIA 58,3 % | Latence 3 s (0,01 s) | 84 Mo

· **Pipeline MLOps :** Drift W_1 > 0.08 | 11 tests PyTest | Coût 0,18 $

· **App & MLflow :** cliner-mlops.onrender.com | Cloud Run (0 €)

· **Dépôt GitHub :** github.com/Elkristobal59/cliner-mlops